

POLITECHNIKA BIAŁOSTOCKA

WYDZIAŁ INFORMATYKI

PRACA DYPLOMOWA INŻYNIERSKA

TEMAT: TEMAT PRACY INŻYNIERSKIEJ /
MAGISTERSKIEJ.

WYKONAWCA: GAL ANONIM

.....
podpis

PROMOTOR: DR INŻ. DOKTOR INŻYNIER

.....
podpis

BIAŁYSTOK 2021 r.

Karta dyplomowa

| | | |
|---|---|---|
| POLITECHNIKA BIAŁOSTOCKA Wydział..... | Studia..... stacjonarne/niestacjonarne | Nr albumu studenta..... |
| | studia I stopnia/studia II stopnia | Rok akademicki..... |
| | | Kierunek studiów..... Specjalność..... |
| <p>.....</p> <p>Imiona i nazwisko studenta</p> <p>TEMAT PRACY DYPLOMOWEJ:</p> <p>.....</p> <p>.....</p> <p>.....</p> <p>Zakres pracy:</p> <p>1.</p> <p>2.</p> <p>3.</p> <p>4.</p> <p>Słowa kluczowe (max 5):</p> <p>TO JEST SKAN</p> <p>.....</p> <p><i>Imiona i nazwisko, stopień/ tytuł promotora - podpis</i></p> | | |
| <p>.....</p> <p><i>Data wydania tematu pracy dyplomowej Regulaminowy termin złożenia pracy dyplomowej Data złożenia pracy dyplomowej</i></p> <p><i>- podpis promotora - potwierdzenie dziekanatu</i></p> | | |
| <p>.....</p> <p><i>Ocena promotora Podpis promotora</i></p> | | |
| <p>.....</p> <p><i>Imiona i nazwisko, stopień/ tytuł recenzenta Ocena recenzenta Podpis recenzenta</i></p> | | |

Subject of diploma thesis

Temat po angielsku.

Summary

Streszczenie pracy po angielsku.

Gal Anonim

Imiona i nazwisko studenta

12345

Nr albumu

informatyka, stacjonarne

Kierunek i forma studiów

dr inż. Doktor Inżynier

Promotor pracy dyplomowej

OŚWIADCZENIE

Przedkładając w roku akademickim 2019/2020 Promotorowi **dr inż. Doktor Inżynier** pracę dyplomową pt.: **Temat pracy**, dalej zwaną pracą dyplomową, **oświadczam, że:**

- 1) praca dyplomowa stanowi wynik samodzielnej pracy twórczej;
- 2) wykorzystując w pracy dyplomowej materiały źródłowe, w tym w szczególności: monografie, artykuły naukowe, zestawienia zawierające wyniki badań (opublikowane, jak i nieopublikowane), materiały ze stron internetowych, w przypisach wskazywałem/am ich autora, tytuł, miejsce i rok publikacji oraz stronę, z której pochodzą powoływane fragmenty, ponadto w pracy dyplomowej zamieściłem/am bibliografię;
- 3) praca dyplomowa nie zawiera żadnych danych, informacji i materiałów, których publikacja nie jest prawnie dozwolona;
- 4) praca dyplomowa dotychczas nie stanowiła podstawy nadania tytułu zawodowego, stopnia naukowego, tytułu naukowego oraz uzyskania innych kwalifikacji;
- 5) treść pracy dyplomowej przekazanej do dziekanatu Wydziału Informatyki jest jednakowa w wersji drukowanej oraz w formie elektronicznej;
- 6) jestem świadomy/a, że naruszenie praw autorskich podlega odpowiedzialności na podstawie przepisów ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (Dz. U. z 2019 r. poz. 1231, późn. zm.), jednocześnie na podstawie przepisów ustawy z dnia 20 lipca 2018 roku Prawo o szkolnictwie wyższym i nauce (Dz. U. poz. 1668, z późn. zm.) stanowi przesłankę wszczęcia postępowania dyscyplinarnego oraz stwierdzenia nieważności postępowania w sprawie nadania tytułu zawodowego;
- 7) udzielam Politechnice Białostockiej nieodpłatnej, nieograniczonej terytorialnie i czasowo licencji wyłącznej na umieszczenie i przechowywanie elektronicznej wersji pracy dyplomowej w zbiorach systemu Archiwum Prac Dyplomowych Politechniki Białostockiej oraz jej zwielokrotniania i udostępniania w formie elektronicznej w zakresie koniecznym do weryfikacji autorstwa tej pracy i ochrony przed przywłaszczeniem jej autorstwa.

.....

czytelny podpis studenta

Spis treści

| | |
|---|-----------|
| Streszczenie | 5 |
| Wstęp | 11 |
| 1 Ogólny problem | 13 |
| 1.1 Problem komiwożacza | 13 |
| 1.2 Metody optymalizacji | 15 |
| 2 Algorytm genetyczny - Paweł | 21 |
| 2.1 Wprowadzenie do algorytmu | 21 |
| 2.2 Parametry wejściowe | 24 |
| 2.3 Metody krzyżowania | 26 |
| 2.4 Metody mutacji | 29 |
| 3 Algorytm mrówkowy | 31 |
| 3.1 Wprowadzenie do algorytmu | 31 |
| 3.2 Opis działania algorytmu | 32 |
| 3.3 Feromony | 34 |
| 4 Algorytmy zachłanne | 39 |
| 4.1 Algorytm najbliższego sąsiada | 39 |
| 4.2 Algorytm najmniejszej krawędzi | 41 |
| 4.3 Algorytm A* | 44 |
| 4.4 Optymalizacja otrzymanych rozwiązań | 44 |
| 5 Zbiór danych | 47 |
| 6 Badania | 49 |
| 6.1 Trasa I | 49 |
| 6.2 Trasa II | 59 |
| 6.3 Trasa III | 71 |

| | |
|--------------------------|------------|
| 7 Rysunki Przemek | 83 |
| 7.1 Trasa 1 | 83 |
| 7.2 Trasa 2 | 83 |
| 7.3 Trasa 3 | 83 |
| Podsumowanie | 89 |
| Bibliografia | 91 |
| Spis tabel | 94 |
| Spis rysunków | 97 |
| Spis listingów | 99 |
| Spis algorytmów | 101 |

Wstęp

Odpady generowane przez mieszkańców są jednym z problemów z jakimi władze muszą sobie radzić w Polsce. Nie jest to problem jedynie wielkich metropolii ale również mniejszych miasteczek. Ilość produkowanych śmieci jest olbrzymia, a to również powoduje kolejne problemy. Segregacja oraz składowanie to nie jest jedyny problem z jakim można się spotkać. Kolejnym utrudnieniem jakie można wyróżnić jest ich transport.

W 2018 roku w Białymstoku został zorganizowany 24-godzinny Hackaton Miejski w Białostockim Parku Naukowo-Technologicznym. Organizatorzy tego przedsięwzięcia przygotowali dużą ilość merytorycznych materiałów na temat zbiórki odpadów komunalnych w mieście Białystok. Uczestnicy hackatonu zauważyli wiele problemów z jakimi boryka się miasto. Jednak największą uwagę organizatorów przykuły inne anomalie.

Jedna z grup zauważyła, że trasy jakie pokonują ciężarówki są nieoptymalne. Jako przykład została przedstawiona droga losowej ciężarówki. Można było zauważyć, że przebyta ścieżka przecina się w wielu miejscach. Na podstawie tylko jednego przykładu można dojść do wniosku, że problem jest globalny i może dotyczyć wszystkich tras. Organizatorzy przedsięwzięcia przyznali, że nie przykładali do tego aspektu uwagi ale może to być kluczowe w oszczędności czasu oraz pieniędzy.

Przy pomocy komputerów oraz odpowiednio napisanego programu można wyznaczyć ścieżki które będą spełniać założenia biznesowe oraz będą odpowiednio optymalne. Wyzwaniem jest jedynie znalezienie odpowiedniego rozwiązania które nada prawidłowy kierunek przeprowadzanym optymalizacjom. Na przestrzeni lat zostało opracowanych wiele rozwiązań. Niestety nie każde rozwiązanie jest w stanie poradzić sobie z konkretnymi danymi w ten sam sposób.

Celem pracy jest zastosowanie i porównanie algorytmów optymalizacji w celu znalezienia najkrótszych tras przejazdu ciężarówek z odpadami komunalnymi. Dla algorytmów zostaną znalezione takie parametry wejściowe aby wynik ich prac był jak najbardziej optymalny. Po przeprowadzeniu badań, rozwiązania zostaną porównane pod kątem optymalizacji oraz szybkości działania.

W rozdziale 2 Paweł Stypułkowski przedstawił algorytm genetyczny. W tym rozdziale można znaleźć informacje w jaki sposób działa to rozwiązanie. Dogłębnie zostały opisane

składowe tego algorytmu. Można się z tego dowiedzieć o parametrach wejściowych, metodach krzyżowania i metodach mutacji.

Kamil Łętowski w rozdziale 3 zaproponował optymalizację tras przy pomocy algorytmu mrówkowego. Oprócz wprowadzenia do algorytmu został zawarty opis działania. Autor swoją uwagę skupił również na bardzo ważnej składowej tego rozwiązania jakim są feromony wykorzystywane przez mrówki.

Algorytmy zachłanne to rozwiązanie jakie zaproponował Przemysław Noskiewicz w rozdziale 4. Autor tego rozdziału opisuje kilka wybranych metod optymalizacji. Wśród nich można wymienić algorytm najbliższego sąsiada, algorytm najmniejszej krawędzi, algorytm a^* . Na sam koniec za pomocą różnych metod algorytmy te zostały ponownie zoptymalizowane.

Po teoretycznym wstępie zostały przedstawione zbiory danych na których pracowały algorytmy. W dalszej kolejności zostały pokazane wyniki jakie udało się osiągnąć poszczególnemu rozwiązaniu. Nie zabrakło również zestawienia oraz porównania najlepszych osiągnięć.

1. Ogólny problem

Badany problem jest w informatyce nazywany problemem komiwojażera. W tym rozdziale zostanie on omówiony oraz metody optymalizacji.

1.1 Problem komiwojażera

Problem komiwojażera (ang. travelling salesman problem - TSP) należy do rodziny problemów NP-trudnych. Znalezienie najlepszego rozwiązania jest trudne i fascynuje naukowców od wielu lat. Niektórzy poddają pod wątpliwość znalezienie efektywnego rozwiązania, czyli takiego którego czas działania jest maksymalnie wielomianowy. Aktualnie istnieje wiele rozwiązań tego problemu, a proponowane podejścia są bardzo interesujące. Niektóre z nich bazują na lokalnych przeszukiwaniach grafu, a inne opierają się na przykładach które występują w przyrodzie.


Podobnym problemem do TSP jest problem konika szachowego. Problem ten również należy do rodziny problemów NP-zupełnym. Już w XVIII wieku badania nad tym problemem rozpoczął Euler. Rozwiązanie tego problemu polega na znalezieniu ścieżki jaką ma przebyć konik szachowy, tak aby odwiedzić każde pole na szachownicy tylko i wyłącznie raz. Skoczek porusza się po planszy zgodnie z określonym ruchem, a plansza szachowa może mieć różny rozmiar. Konik porusza się aż do momentu odwiedzenia wszystkich pól lub do momentu w którym nie ma możliwości odwiedzenia kolejnego pola.

Optymalizacja tras od zawsze jest obecna w historii ludzkości. Nawet takie trywialne problemy jak podróż pomiędzy 3 miejscowościami może zostać sklasyfikowany jako problem komiwojażera. Chociaż dokładne wskazanie na źródło problemu TSP nie jest znane, to już w 1832 roku w przewodniku dla podróżujących po Niemczech i Szwajcarii została zawarta informacja o optymalizacji trasy przejazdu. Nie ma tam zawartych żadnych teorii matematycznych w związku z czym nie można uznać tego dzieła za początek rozważań nad problemem komiwojażera.[?]

W XIX wieku William Hamilton stworzył fundamenty pod definicję TSP. W rozwiązaniu problemu komiwojażera należy znaleźć cykl w grafie. W skład takiego cyklu musi zostać zawarty każdy z wierzchołków. Każdy z wierzchołków może znajdować się w rozwiązaniu dokładnie tylko raz. Cykl który spełnia wymieniony warunek jest cyklem


Hamiltona. Jeśli w grafie można wyróżnić cykl z opisanymi powyżej warunkami, to graf jest grafem Hamiltonowskim.

Na ?? został przedstawiony graf bez cyklu Hamiltona. W grafie tym nie można znaleźć takiego połączenia które zawiera wszystkie wierzchołki przechodząc przez każdy z nich dokładnie raz. Istnieje możliwość przejścia przez wszystkie wierzchołki jedynie po powtórnym odwiedzeniu przynajmniej jednego wierzchołka.



Rysunek 1.1: Graf bez cyklu Hamiltona.

Graf z ?? posiada połączenie krawędzi dzięki któremu można przejść po wszystkich wierzchołkach dokładnie raz. Takie przejście jest właśnie cyklem Hamiltona w związku z czym graf jest Hamiltonowski. Wyruszając przykładowo z punktu F możemy przejść kolejno do E - G - D - B - A - C. W ten sposób odwiedzimy wszystkie wierzchołki tylko raz.



Rysunek 1.2: Graf z cyklem Hamiltona.

W latach 30 XX wieku Merrill Meeks Flood rozpoczął rozważania nad optymalizacją przejazdu autobusów szkolnych. Działalność tą możemy uznać za początek pracy nad problemem TSP. Wraz z upływem czasu zainteresowanie problemem optymalizacyjnym narastało, a co za tym idzie powstawały nowe pomysły na algorytmy. Jednak żaden z pomysłów nie jest w stanie zaproponować dokładnego rozwiązania które jest w stanie przedstawić rezultat w czasie wyrażonym za pomocą wielomianu.

1.2 Metody optymalizacji

Jednym z proponowanych rozwiązań jest algorytm Helda Karpa który jest oparty na programowaniu dynamicznym. Złożoność pamięciowa tego algorytmu wynosi $\theta(2n^n)$, a czasowa $\theta(n^2 * 2^n)$. W algorytmie tym na każdym kroku wyznaczamy punkt który powinien być przedostatni na trasie. Aby wyznaczyć poprzednika należy skorzystać ze wzoru w którym poszukiwana jest najmniejsza wartość pomiędzy punktami.

Innym przykładem, który można wykorzystać do rozwiązania problemu komiwojagera jest algorytm najbliższego sąsiada. Rozwiązanie to wykorzystuje strategię zachłanną. W algorytmie szukamy aktualnie najlepszego ruchu. W tym celu przeszukiwani są jedynie sąsiedzi którzy są najbliżej aktualnego punktu. Złożoność takiego algorytmu jest szacowana na $\theta(n^2)$.

Oprócz standardowych przeszukiwań zbiorów na przestrzeni lat pojawiły się propozycje które wprowadzają elementy losowości. Przykładem takiego rozwiązania mogą być algorytm genetyczny oraz algorytm mrówkowy. Należą one do grup algorytmów heurystycznych, czyli do takich, które nie dają gwarancji znalezienia dokładnego rozwiązania.

W pracy zostaną zbadane rozwiązania problemu za pomocą algorytmu genetycznego, mrówkowego oraz zachłannego. W pozostałych podrozdziałach zostaną opisane ich klasyczne wersje.

1.2.1 Algorytm genetyczny - Paweł

Algorytm genetyczny (ang. *GA - Genetic Algorithm*) polega na symulacji procesów genetycznych zachodzących w populacjach osobników, stosuje się je głównie przy zadaniach optymalizacyjnych. W przyrodzie większość gatunków od wieków, w tym przede wszystkim i człowiek, w kolejnych swoich pokoleniach się rozwinęło i dostosowało do otaczających warunków na świecie. Gdy jakiś osobnik urodzi się z cechą, która jest przydatna w

przetrwaniu, przekażę tę cechę kolejnym pokoleniom. Najslabsze osobniki w populacji mają zarówno mniejsze szanse na przetrwanie oraz rozmnożenie, czyli przekazanie swoich cech potomkom. W przyrodzie zazwyczaj silniejsi wygrywają. W latach 50 XX wieku zaczęto symulować te procesy w informatyce. W latach 60 John Henry Holland zastosował algorytm genetyczny przy pracach nad systemami adaptacyjnymi, a 1975 wydał książkę *Adaptation in Natural and Artificial Systems*, w której to opisał.[7]. Algorytm genetyczny poszukuje najlepsze rozwiązania, wśród populacji potencjalnych rozwiązań. Jest to główna cecha, która odróżnia go od tradycyjnych metod optymalizacji. Każde rozwiązanie ulega ocenie na podstawie jego dopasowania do problemu - funkcja przystosowania. Algorytm na populacji symuluje zjawiska ewolucyjne, krzyżując i mutując rozwiązania, stosując probabilistyczne reguły wyboru. W każdym takim nowym pokoleniu najslabsi są usuwani, więc w kolejnych etapach populacja składa się z coraz to lepszych rozwiązań [?]. Kolejne pokolenia są generowane, aż zostanie spełniony warunek zakończenia. Może to być z góry ustalony czas trwania, ilość kolejnych pokoleń lub brak poprawy wśród nowych rozwiązań.

Algorytmy genetyczne i jego odmiany zrewolucjonizowały systemy informatyczne. Nie są one algorytmami, które wyliczają dokładne wyniki, ale przy odpowiedniej implementacji i ustaleniu parametrów wejściowych, pozwalają osiągnąć dobre rezultaty. Bardzo ważny jest czas znalezienia takiego rozwiązania. Jeśli rozwiązanie idealne obliczane jest przez algorytm tradycyjny w ciągu 24 godziny, a algorytm genetyczny w trakcie kilku minut znajdzie rozwiązanie będące w sąsiedztwie, swoją efektywnością wygra ten drugi. Użytkownik nie będzie chciał czekać całej doby na wynik swojego zapytania. Oczywiście, algorytmy genetyczne też mogą znaleźć najlepsze rozwiązanie. Kwestią ograniczenia jest zawsze czas.

Medycyna jest jedną z ważniejszych dziedzin, gdzie wykorzystuje się algorytmy genetyczne. Zbiory danych i przestrzeń przeszukiwań jest ogromna i złożona. Zazwyczaj w oparciu o te informacje, lekarz musi podjąć decyzję, czy np. nowotwór jest złośliwy, czy ma łagodny przebieg. Algorytm genetyczny pozwala wspomóc lekarza przy podejmowania takich decyzji, przetwarzając i analizując te ogromne zbiory. [4]. Kolejną gałęzią gospodarki, w których zastosowanie znajduje algorytm genetyczny, jest przemysł spożywczy, a konkretnie optymalizacja linii produkcyjnych. Za ich pomocą algorytmu genetycznego wyznacza się parametry takie jak temperatura, ciśnieniu lub zapotrzebowanie mocy. Dzięki temu wszystkie procesy technologiczne zachodzące w maszynach i urządzeniach są wydajne

i zoptymalizowane[?]. Algorytmy genetyczne często stosuje się jako wskazanie punktów początkowych w innych metodach optymalizacyjnych. Poza podanymi przykładami, znajdują one zastosowanie praktycznie wszędzie: ekonomia, giełda, przemysł lotniczy, kombinatoryka, sieci komputerowe, zarządzanie łańcuchem dostaw, a także ustalanie czasu reklamy w telewizji [?].

1.2.2 Algorytm mrówkowy

Obserwacje nad zachowaniami w przyrodzie wielokrotnie miały wpływ na rozwój nowych rozwiązań. Tak jak w przypadku algorytmu genetycznego, tak i w przypadku algorytmu mrówkowego pomysł został zaczerpnięty z przyrody. Dokładne działanie algorytmu mrówkowego wzoruje się na zachowaniu kolonii mrówek. Dzięki pracy zespołowej, owady te są w stanie wypracować optymalną ścieżkę między siedliskiem a znalezionym pokarmem.

Dla niejednego gatunku problematyczne mogłoby być odtworzenie przebytej ścieżki. Na początku należałoby zadać sobie pytanie w jaki sposób te niewielkich rozmiarów owady są w stanie znacząco ułatwić sobie przetrwanie? Istotną rolę odgrywa tutaj wspomniana już praca zespołowa. To dzięki niej mrówki są w stanie optymalizować trasę. Innym ważnym czynnikiem determinującym poprawę ścieżki jest zapach jaki zostawiają mrówki.

Zapach nie jest niczym innym jak feromonem wytwarzanym przez mrówki. Dzięki pozostawionemu zapachowi mrówki identyfikują w jaki sposób poruszali się ich poprzednicy w związku z czym odtworzenie trasy nie stanowiło już poważnego problemu. Przy kolejnych iteracjach, kolonia próbuje optymalizować aktualną trasę. W tym celu również wykorzystuje zapach pozostawiony w poprzednich przejściach. Ścieżka jest losowo zmieniana w celu optymalizacji. Jeśli modyfikacja przyniosła oczekiwany efekt, to trasa zostaje zmieniona.

Algorytm mrówkowy znajduje swoje zastosowanie w rozwiązywaniu innych problemów. Problem plecakowy jest jednym z takich przykładów. Pojawia się on najczęściej przy optymalnym zarządzaniu zasobami. Mamy dany zbiór jakichś przedmiotów z czego każdy z nich posiada określony ciężar i wartość. Do plecaka musimy załadować przedmioty o jak największej wartości. Naszym ograniczeniem jest jednak łączny ciężar przedmiotów które możemy udźwignąć.

Algorytm mrówkowy wygląda bardzo podobnie w tym przypadku. Na początku jest N agentów - mrówek. Każdy agent iteracyjnie poszukuje jak najlepszego rozwiązania. Po każdej iteracji można wyróżnić trzy typy rozwiązań: rozwiązanie pośrednie, rozwiązanie

częściowe lub stan. Agenci w celu znalezienia rozwiązania wykorzystują swoje naturalne umiejętności czyli zostawiają na wszystkich obiektach w plecaku feromony. Dzięki lotności feromonów mrówki są w stanie identyfikować bardziej zadowalające przedmioty.

Krzysztof Schiff w artykule Ant colony optimization algorithm for the 0-1 knapsack[?] przedstawił rozwiązanie problemu plecakowego. Do wyboru najlepszego rozwiązania wykorzystane zostały trzy metody. Zgodnie z przyjętą konwencją przez autora artykułu metody mają odpowiednie nazwy: AKA1, AKA2 oraz AKA3. Za wybór najlepszego rozwiązania odpowiadają wzory:

$$AKA1 = \frac{z}{w}$$

$$AKA2 = \frac{z}{w^2}$$

$$AKA3 = \frac{z}{\frac{w}{C}}$$

gdzie:

- z jest zyskiem wybranego obiektu;
- w jest wagą wybranego obiektu;
- V jest aktualną ładownością plecaka;
- z jest zyskiem wybranego obiektu;
- C jest całkowitą wagą plecaka.

Problem komiwojażera i problem plecakowy są problemami kombinatorycznymi. Ich rozwiązanie polega na poszukiwaniu optymalnej ścieżki na grafie pełnym. Inną odmianą problemu jest kolorowania grafu. W tej wariacji problem jest od razu zadany na grafie. Dla wszystkich wierzchołków w grafie należy dobrać takie kolory, aby żadne dwa sąsiednie wierzchołki nie miały tego samego koloru [?].

Mrówki nie działają bezpośrednio na grafie początkowym ponieważ graf ten nie musi być grafem pełnym. Należy stworzyć dla mrówek alternatywę podobną do oryginału z zachowaniem takiego samego zbioru wierzchołków ale z pełnymi krawędziami. Następnie należy dobrać numeryczne wartości odpowiadające konkretnym kolorom. Jeśli mrówka odwiedzi dany wierzchołek, to zostaje on pokolorowany na najniższy kolor który nie został dotychczas użyty do kolorowania któregoś z sąsiadów.

Tak jak w przypadku poprzednich algorytmów wykorzystywane są zapachy pozostawiane przez mrówki. Ilość użytych unikalnych kolorów byłaby odwrotnie proporcjonalna

do ilości feromonów. W efekcie czego heurystyka byłaby odwrotnie proporcjonalna do wykorzystanych kolorów po kolejnych iteracjach. Wynikiem tych operacji będzie rozwiązanie w którym, w grafie oryginalnym każdy wierzchołek będzie odwiedzany tylko raz.

Ostatni z przykładów wykorzystania algorytmu mrówkowego jest harmonogram produkcji. W porównaniu do poprzednich metod w tym algorytmie zachodzi pewna modyfikacja. Głównym problemem w harmonogramie produkcji jest znalezienie takiej kolejności przetwarzanych zadań, aby jak najszybciej je przetworzyć. Aby lepiej zobrazować tą sytuację należy sobie wyobrazić fabrykę w której znajdują się linie produkcyjne. Na linii są przetwarzane zadania w odpowiedniej kolejności oraz każde z zadań może zostać wykonane w różnym czasie[?].

W tej metodzie, podobnie jak w metodzie do rozwiązania problemu plecakowego, należy stworzyć graf pełny z wierzchołkami odpowiadającymi konkretnym zadaniom. Następnie mrówki przechodzą przez wszystkie wierzchołki i zostawiają feromony. Czynnikiem decydującym o wyborze wierzchołków nadal jest związana z feromonami. Do rozwiązania tego problemu nie jest brana pod uwagę liczba feromonów na krawędzi pomiędzy wierzchołkiem a jego sąsiadami. Wykorzystywana jest natomiast suma feromonów na wszystkich krawędziach do odwiedzanych wierzchołków z wierzchołkami już odwiedzionymi.

1.2.3 Algorytmy zachłanne

Kolejnym spojrzeniem na poruszany w pracy problem komiwojażera są algorytmy zachłanne (ang. *greedy algorithms*). Nie łatwo znaleźć dowód na to czy dla podanego problemu algorytm zachłanny znalazł poprawny wynik, jednak stosując się do pewnych zasad można określić, że dla danego problemu istnieje rozwiązanie zachłanne. Główną strategią jaką się kierują jak sama nazwa naprowadza jest dokonywanie wyborów, które w danej chwili wydają się najlepsze. Oznacza to, że dokonuje się wyborów optymalnych lokalnie w nadziei, że te wybory doprowadzą do rozwiązania globalnego w zadowalającym czasie. W odróżnieniu do strategii zastosowanej w programowaniu dynamicznym wybory podejmowane przez algorytmy zachłanne nie są uzależnione od wyborów przeszłych. Kolejnym kryterium stosowanym do ocenienia poprawności rozwiązania zachłannego jest własność optymalnej pod struktury, mówiąca o tym, że optymalne rozwiązanie dla całego problemu istnieje jedynie przy optymalnym rozwiązaniu pod problemów. Dane kryterium jest również istotne

w przypadku rozwiązywania problemów metodą programowania dynamicznego. Algorytmy zachłanne nie zawsze prowadzą jednak do optymalnych rozwiązań, jednakże dla większości problemów dają wystarczające rezultaty. Skorzystanie z algorytmów zachłannych często okazuje się niewystarczające. Aby uzyskać lepszy efekt i polepszyć zbudowane już trasy możemy wykorzystać algorytmy lokalnej optymalizacji (ang. *local search*). Użycie ich na zwróconych przez algorytmy zachłanne trasach powinno zminimalizować odległości między wierzchołkami w celu poprawienia otrzymanego rozwiązania. Dokładniejszy opis działania wybranych algorytmów zachłannych i metod optymalizujących został przedstawiony w podrozdziałach.

Już w latach pięćdziesiątych została zastosowana koncepcja algorytmów zachłannych do przeszukiwania grafów, gdzie Esdger Wybe Dijkstra dążąc do skrócenia tras w Amsterdamie, stolicy Holandii opracował technikę do generowania minimalnych drzew rozpinających. Również w tej samej dekadzie Robert Clay Prim oraz Joseph Bernard Kruskal opracowali strategie optymalizacji, które opierały się na minimalizacji kosztów dla ważonych tras. Do dzisiaj stworzone algorytmy są wykorzystywane w mapach geograficznych do wyznaczania najkrótszych ścieżek, do znajdowania OSPF (ang. *Open Shortest Path First*) w protokole routingu IP (ang. *Internet Protocol*) czy w sieciach telefonicznych.

2. Algorytm genetyczny - Paweł

W tym rozdziale zostanie przedstawiony sposób, w jaki zostanie zastosowany algorytm genetyczny przy wyznaczaniu najlepszych tras dla ciężarówek przewozu odpadów komunalnych.


2.1 Wprowadzenie do algorytmu

Przed przejściem do omawiania algorytmu, należy wyjaśnić podstawowe pojęcia, które występują w algorytmie genetycznym:

- OSOBNIK – pojedyncze rozwiązanie problemu, zakodowane w postaci chromosomu,
- POPULACJA – zbiór osobników o stałej liczbie N w przekroju trwania całego algorytmu,
- GEN – przechowuje informację o dowolnej cesze osobnika. W zależności od sposobu kodowania może to być bit, dowolna cyfra lub znak,
- CHROMOSOM – składa się z uporządkowanego ciągu genów, przechowuje wszystkie cechy osobnika,
- GENOTYP – w przyrodzie może składać się z kilku chromosomów i określa skład osobnika. W algorytmach genetycznych przyjmuje się, że jest to pojedynczy chromosom,
- FUNKCJA PRZYSTOSOWANIA – funkcja za pomocą, której ocenia się jakość osobnika[7].

Schemat blokowy klasycznego algorytmu genetycznego został pokazany na rysunku 2.1. Pierwszym krokiem jest wylosowanie populacji początkowej algorytmu. Wielkość populacji podczas trwania całego algorytmu jest stała N . Ważne jest, aby wszystkie osobniki były jak najbardziej zróżnicowane i wygenerowane losowo. Każdy z nich następnie musi zostać zakodowany do postaci chromosomów, które będą przechowywać w sobie informację o odwiedzanych punktach w postaci genów.


W populacji każdy osobnik musi zostać poddany ocenie funkcji przystosowania. Jej wynik determinuje jak dobre jest dane rozwiązanie. W klasycznym algorytmie dąży się do maksymalizacji tej funkcji. Określenie jak dana funkcja przystosowania będzie wyglądać, jest to jedną z najważniejszych części algorytmu genetycznego. Jeśli zostanie źle zdefiniowana, znalezione osobnik może nie spełniać wymagań rozwiązania problemu.



Rysunek 2.1: Schemat algorytmu genetycznego

Po ocenie osobników zostaje sprawdzony warunek końcowy algorytmu. W zależności od problemu jest zdefiniowany inny warunek. W klasycznych podejściach są trzy różne rodzaje warunków końcowych. Pierwszym popularnym warunkiem końcowym jest stała ilość iteracji algorytmu. Drugim warunkiem jest określenie z góry czasu trwania algorytmu, po upływie którego zostaje wybrany najlepszy osobnik. Ostatnim popularnym warunkiem jest wykonywanie algorytmu, do momentu, aż wyniki przestaną się poprawiać w kolejnych pokoleniach. Wybór w jaki sposób będzie wyglądać warunek końcowy zależy od wielu czynników. Jeśli ważny jest krótki czas, należy założyć pierwszy wariant. Jeśli natomiast algorytm może szukać rozwiązania nawet kilka godzin, można przyjąć drugi wariant, łącząc go jednocześnie z trzecim.

Kolejnym krokiem algorytmu jest wyselekcjonowanie rodziców do reprodukcji. Polega ona na tym, że osobniki lepsze (mają większą wartość oceny przystosowania) mają większe szansę na pozostanie rodzicem i przekazanie swoich cech. [3]. Najpopularniejszymi metodami wyboru rodziców jest metoda ruletki oraz turniejowa.



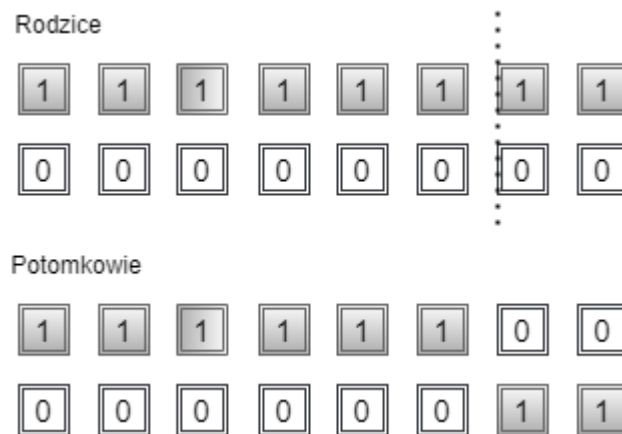
Rysunek 2.2: Metoda ruletki

Na rysunku 2.2 została zilustrowana metoda ruletki. Każdy z osobników dostaje wirtualny wycinek koła fortuny. Jego wielkość zależy od wartości funkcji prawdopodobieństwa. Przy każdym wyborze rodzica następuje zakręcenie koła i do reprodukcji zostaje wybrany osobnik na który będzie wskazywał stały punkt.

W metodzie turniejowej zostaje wybranych r osobników z populacji N . Z pośród nich zostaje wybrany zwycięzca (największa wartość funkcji przystosowania), który trafia do puli rodzicielskiej. Im większa jest ilość osobników r tym mniejsze szanse, że słabsze osobniki zostaną wybrane.


Wybrani rodzice zostają poddani operatorom genetycznym: krzyżowanie (ang. *crossover*) oraz mutacji (ang. *mutation*). Krzyżowanie polega na połączeniu części chromosomu jednego rodzica z częścią drugiego. Wynikiem takiego połączenia jest nowy osobnik. Metody krzyżowania są różne, ale zawsze wykonywane muszą być w ten sam określony sposób. Wszystko zależy od metody zakodowania chromosomu oraz od tego czy kolejność

genów i ich unikalność ma znaczenie. W klasycznym podejściu polega na rozcięciu w dowolnym miejscu genotypu u dwóch osobników oraz skrzyżowaniu ich ze sobą w tym punkcie (Rys. 2.3).



Rysunek 2.3: Klasyczne krzyżowanie

Następnie u nowego osobnika może z prawdopodobieństwem pm wystąpić mutacja. Jest to zmiana dowolnego pojedynczego lub ciągu genów na inny (Rys 2.4). Wartość pm w klasycznych algorytmach jest stosunkowo niska. Mutacja ma na celu delikatne zróżnicowanie osobników w celu przeszukania nowej przestrzeni rozwiązań. Natomiast gdyby zachodziła często, mogłaby powodować niszczenie dobrych rozwiązań. Po zasto-



Rysunek 2.4: Mutacja genotypu

sowaniu wszystkich operatorów genetycznych, nowa populacja jest poddawana ocenie przystosowania i jeśli wystąpił warunek końcowy, wybierane jest najlepsze rozwiązanie.

2.2 Parametry wejściowe

Przy problemie zoptymalizowania tras samochodów wywożących odpady komunalne zostaną zbadane takie parametry wejściowe jak: wielkość populacji, ilość iteracji (pokoleń), czas trwania algorytmu, rodzaj krzyżowania, rodzaj mutacji oraz prawdopodobieństwo

mutacji. Jeśli chodzi o metodę selekcji, to będzie to metoda turniejowa. Poza tymi zmiennymi ważne jest wyznaczenie funkcji przystosowania oraz zakodowania informacji o trasach do postaci chromosomu. W podrozdziałach 2.3 oraz 2.4 zostaną opisane trzy rodzaje mutacji oraz krzyżowań, które zostaną zbadane.

2.2.1 Chromosom

W algorytmie genetycznym, każdy osobnik z populacji reprezentuje jedno rozwiązanie. Jakość takiego rozwiązania jest zapisywana do zakodowanej postaci chromosomu. Chromosom z definicji jest to ciąg genów reprezentujący dane rozwiązanie. Z kolei gen przenosi informację o cechach. Możliwość osiągnięcia sukcesu w algorytmie genetycznym jest tylko wtedy, gdy odpowiednio zakoduje się cechy i ustali funkcję przystosowania. Do zakodowania badanego problemu zostanie użyta metody permutacyjna bez powtórzeń. Permutacja to jest dowolnie utworzony ciąg ze wszystkich elementów zbioru. Każdemu genowi przed zakodowaniem chromosomów zostanie przypisany unikalny indeks. Będzie on przechowywał informację, który punkt jest odwiedzany. Następnie dla każdego z N osobników zostanie zakodowany chromosom w postaci ciągu permutacyjnego. Kolejną warunkiem jaki musi spełnić chromosom to pierwszy i ostatni gen, nigdy nie może zmienić swojego miejsca. Punkt startowy zawsze musi zostać na miejscu pierwszym, jak również punkt rozładunkowy musi być na końcu. Na rysunku 2.5 zostały zilustrowane przykłady kodowania permutacyjnego bez powtórzeń, dla chromosomu o długości 8. W obu chromosomach pierwsze i ostatnie miejsca są takie same. W przyszłych podrozdziałach gen będzie oznaczał jeden z punktów załadowań (lub ostatni rozładowania) na trasie ciężarówki. Chromosom będzie oznaczał kolejność odwiedzania tych punktów przez pojazd.



Rysunek 2.5: Kodowanie chromosomów

2.2.2 Funkcja przystosowania

Algorytm genetyczny szuka osobnika z największą wartością funkcji przystosowania. W badanym problemie należy znaleźć najkrótszą trasę. W momencie, gdy długość takiej

trasy zostanie odwrócona, to okaże się, że im większa wartość odwrotności tym krótsza trasa. Zatem wzór funkcji przystosowania to

$$fp = \frac{1}{s + 1}$$


gdzie s - długość trasy, czyli suma odległości pomiędzy genami w chromosomie (1 - 2 - 3 - 4 - 5 - 6 - 7).

2.3 Metody krzyżowania

W pracy zostaną zbadane trzy rodzaje metod krzyżowania. Każde z nich charakteryzuje się czymś innym jeśli chodzi o liczbę potomków oraz porządek genów względem rodziców. Żadne z krzyżowań nie może zaburzyć dwóch warunków. Potomek musi posiadać strukturę permutacyjną oraz pierwszy i ostatni punkt nie mogą się przemieścić.

2.3.1 Krzyżowanie z częściowym odwzorowaniem - PMX


PMX[?] (ang. *Partially Mapped Crossover*) jest odmianą krzyżowania dwupunktowego, w którym powstaje dwójka potomstwa. Zakładając, że wyselekcjonowano dwóch rodziców: 1 - 3 - 6 - 5 - 4 - 7 - 2 - 8 oraz 1 - 2 - 4 - 6 - 5 - 3 - 7 - 8 (Rys. 2.6). Losowane są



Rysunek 2.6: Krzyżowanie PMX - część 1

dwa dowolne punkty (nie uwzględnia się pierwszego i ostatniego), w których się je rozcina, w opisywanym przypadku znajdują się one po trzecim i szóstym genie. Rozcięcia tworzą dwa segmenty 5 - 4 - 7 oraz 6 - 5 - 3, które zamienia się ze sobą. W wyniku tej operacji powstały dwa chromosomy: 1 - 3 - 6 - 6 - 5 - 3 - 2 - 8 oraz 1 - 2 - 4 - 5 - 4 - 7 - 7 - 8.

Oba z nich nie są jeszcze permutacjami. Należy teraz w powtórzone geny, które znajdują się poza segmentami, zamienić na te geny, których brakuje. W tym celu następuje określenie mapowania pomiędzy genami, które następnie zamienia się ze sobą w chromosomach (Rys. 2.7). W pierwszym dziecku należy zamienić odpowiednie geny: 3 -> 4 oraz 6 -> 7. W drugim




Rysunek 2.7: Krzyżowanie PMX - część 2

natomiast zamienia się: 4 -> 6 oraz 7 -> 3. W wyniku tych zmian powstają dwa chromosomy: 1 - 4 - 7 - 6 - 5 - 3 - 2 - 8 oraz 1 - 2 - 6 - 5 - 4 - 7 - 3 - 8. Powstałe dzieci posiadają już strukturę permutacyjną oraz pierwszy i ostatni punkt się nie przemieściły.

2.3.2 Krzyżowanie z zachowaniem porządku - OX

OX[?] (ang. *Order Crossover*) jest również odmianą krzyżowania dwupunktowego. W przeciwieństwie do PMX wynikiem będzie tylko jedno dziecko. Krzyżując ze sobą dwa chromosomy: 1 - 3 - 6 - 5 - 4 - 7 - 2 - 8 oraz 1 - 2 - 4 - 5 - 6 - 3 - 7 - 8. Pierwszym krokiem jest wylosowanie dwóch dowolnych punktów w których zostanie rozcięty pierwszy rodzic. Zakładając podobnie jak przy krzyżowaniu PMX, że są to punkty po trzecim i szóstym genie (Rys. 2.8). Oba punkty tworzą segment 5 - 4 - 7. Następnie w drugim rodzicu należy usunąć




Rysunek 2.8: Krzyżowanie OX

geny, które zostały z pierwszego rodzica wycięte. Ostatnim krokiem jest wstawienie wycinka

5 - 4 - 7 do drugiego rodzica, w to samo miejsce z jakiego zostały usunięte w pierwszym rodzicu. Powstał potomek 1 - 2 - 6 - 5 - 4 - 7 - 3 - 8, który spełnia założenia.

2.3.3 Krzyżowanie cykliczne - CX

CX[?] (ang. *Cycle Crossover*) w przeciwieństwie do PX i OX nie polega na krzyżowaniu w dwóch określonych punktach. Aby wyznaczyć potomka, należy w dowolnym rodzicu znaleźć cykl permutacji, zaczynając od dowolnego miejsca pomiędzy pierwszym i ostatnim genem. Szukanie cyklu polega na kopiowaniu genów z jednego rodzica, według pozycji określonych przez rodzica drugiego. Na rysunku przedstawiono krzyżowanie CX dla dwóch chromosomów: 1 - 3 - 6 - 5 - 4 - 7 - 2 - 8 oraz 1 - 2 - 4 - 5 - 6 - 3 - 7 - 8. Losowany jest punkt startowy, inny niż 1 oraz 8. Na rysunku 2.9 został wylosowany



Rysunek 2.9: Krzyżowanie CX


drugi gen, czyli 3. Jego odpowiednikiem w drugim rodzicu jest 2. Należy znaleźć ten gen w pierwszym rodzicu. Znajduje się on na siódmym miejscu, jego odpowiednikiem jest gen 7. Ten gen jest na szóstym miejscu, a jego odpowiednikiem jest 3. W tym momencie został znaleziony cykl, ponieważ zaczynał się od 3 i nastąpiło zapętlenie. Znaleziony cykl to 3 - 2 - 7. Kolejnym krokiem jest wycięcie cyklu z chromosomu, w którym został wyznaczony. W ten sposób zostaje przepisane X - 3 - X - X - X - 7 - 2 - X. Aby skończyć krzyżowanie, w X należy wpisać geny z drugiego rodzica, które nie wystąpiły w cyklu. W tak powstałym dziecku 1 - 3 - 4 - 5 - 6 - 7 - 2 - 8, wszystkie geny zajmują taką samą pozycję jak w którymś z rodziców, inaczej niż to było przy krzyżowaniu OX.

2.4 Metody mutacji

W pracy zostaną zbadane trzy różne rodzaje mutacji. Są to specjalne mutacje wykorzystywane przy strukturach permutacyjnych. Każda z nich zostanie również zbadana z różną wartością pm . Z reguły nie może być one duże, aby nie niszczyć potencjalnych rozwiązań. Powinno delikatnie wprowadzać różnorodność, aby była możliwość przeszukiwać nowe obszary. Poza tym bardzo ważne jest, aby zmiany powstałe w wyniku mutacji nie zaburzały struktury permutacyjnej chromosomu. Wszystkie mutacje zostaną opisane na tym samym chromosomie 1 - 2 - 3 - 4 - 5 - 6 - 7 - 8.

2.4.1 Mutacja odwracająca

W mutacji odwracającej (ang. *revert mutation*) odwracającej wybierany jest dowolny podciąg genów z chromosomu, a następnie ich kolejność jest odwracana. Załóżmy, że wybrany podciąg to 3 - 4 - 5 (Rys. 2.10). W tym przypadku składa się on z trzech genów, więc po odwróceniu zamienią się ze sobą dwa geny, środkowy zostanie na tym samym miejscu. Po mutacji końcowy chromosom ma postać 1 - 2 - 5 - 4 - 3 - 6 - 7 - 8. Struktura permutacyjna nie została zachwiana.




Rysunek 2.10: Mutacja odwracająca

2.4.2 Mutacja wstawiająca

W tej mutacji wstawiającej (ang. *insert mutation*) dowolny gen jest przestawia się w losowe miejsce. Jest to najprostsza mutacja, ale teoretycznie, może generować rozwiązań w całkowicie nowych przestrzeniach przeszukiwań. Punkt znajdujący się na końcu trasy, może znaleźć się na początku. Na rysunku 2.11 został wylosowany gen 5, który znajdował


się na piątym miejscu, po mutacji znalazł się na drugim miejscu, w rezultacie chromosom po mutacji ma postać 1 - 5 - 2 - 3 - 4 - 6 - 7 - 8.



Rysunek 2.11: Mutacja wstawiająca

2.4.3 Mutacja zamieniająca

W mutacji zamieniającej (ang. *swap mutation*) zamienia się dwa dowolne geny miejscami. Jest to tak naprawdę, rozszerzona wersja mutacji wstawiającej. Losowane są dwa dowolne geny, na rysunku 2.12 są to 2 i 5, które ulegają zamianie miejscami. Powstały chromosom to 1 - 5 - 3 - 4 - 2 - 6 - 7 - 8.



Rysunek 2.12: Mutacja zamieniająca

3. Algorytm mrówkowy

Słowo rozwój może być zestawiane z wieloma rzeczownikami. Wiele dziedzin ciągle się rozwija, powstają nowe udogodnienia które wpływają na wiele dziedzin życia. Dzięki rozwojowi techniki ludzie są w stanie osiągać cele które jakiś czas temu mogły być tylko marzeniami. Rozwój techniki również potrzebuje inspiracji do tworzenia nowych, lepszych rozwiązań

Szybkość oraz dokładność rozwoju zależy od wielu czynników. Dzięki pracy zespołowej pewne problemy mogą być rozwiązywane szybciej i dokładniej. Wysiłek włożony przez grupę procentuje szybko, a same efekty mogą być również satysfakcjonujące. Istotnym czynnikiem jest wysiłek wkładany przez każdego członka grupy.

Obserwując przyrodę możemy zauważyć w jaki sposób zwierzęta radzą sobie z różnymi problemami. Złożone grupy mogą być spokojniejsze o zdobycie pożywienia czy też o przetrwanie w ciężkich warunkach. Praca zespołowa jest jedną z cech której osobniki w grupie uczą się nie będąc nawet tego do końca świadomym.

3.1 Wprowadzenie do algorytmu

Na przestrzeni czasu wiele gatunków zwierząt żyjących na ziemi przystosowało się do panujących tu warunków. Jedną z takich gatunków są mrówki. Te niewielkich rozmiarów owady posiadają zdolności pomagające im przetrwać wśród najcięższych warunków. Mrówki żyją w stadach w związku z czym wykorzystują pracę zespołową do rozwiązywania problemów jakie codziennie napotykają na swojej drodze.

Aby zapewnić przetrwanie stada mrówki potrzebują zapewnić sobie dostęp do pokarmu. Dziesiątki tysięcy mrówek mają swoje schronienie w mrowiskach. To tam trafia zdobyty przez nich pokarm. Wystarczy aby jedna mrówka znalazła miejsce z pokarmem, to po powrocie do mrowiska inne osobniki są w stanie odtworzyć drogę do pożywienia. Na tym etapie należałoby się zastanowić, w jaki sposób mrówki są w stanie komunikować się między sobą?

Jednym z opisywanych przez nas rozwiązań do wyznaczania zoptymalizowanej trasy jest algorytm mrówkowy, inaczej nazywany ACO - Ant Colony Optimization. Pomysł ten został zaczerpnięty z natury. Jak sama nazwa wskazuje działanie algorytmu jest związane z

mrówkami, a dokładnie z kolonią mrówek. Pomysł na algorytm został zaproponowany na początku lat 90 XX wieku przez włoskiego badacza - Marco Dorigo.

Tak jak zostało wspomniane wcześniej, algorytm opiera się na pracy mrówek. Chodzi tutaj dokładnie o trasę jaką mrówki pokonują od swojego siedliska do miejsca w którym znajduje się pożywienie. Ważne jest znaczenie tutaj pracy zespołowej. Trasę kształtuje cała kolonia mrówek, a nie pojedyncze przypadki. Mrówki z każdą kolejną podróżą wykształcają coraz to bardziej optymalną trasę.


3.2 Opis działania algorytmu

Mrówka w celu znalezienia pokarmu w sposób losowy wyrusza z mrowiska. Losowo przesuując się po terenie szuka pokarmu. Gdy już go znajdzie wraca do siedliska i informuje o tym fakcie pozostałe mrówki. Aby dostarczyć więcej pokarmu mrówki wyruszają do miejsca spoczynku pożywienia. Chcąc uniknąć sytuacji w której zdobycz może zostać zabrana przez inne owady, mrówki muszą jak najbardziej zoptymalizować trasę jaką mają do pokonania.


Mimo posiadania informacji o znalezionym pokarmie, każda mrówka sama musi zlokalizować źródło. Czy mrówki poruszają się tą samą trasą przy każdym wyjściu z mrowiska? Aby trafić do miejsca w którym znajduje się pokarm, wspomniane owady wykorzystują ślady pozostawione przez osobników które już natrafiły na pożywienie. W ten sposób mrówka która wyrusza w sposób losowy, natrafia na ślad poprzednika który jest wskazówką do znalezienia poszukiwanego pokarmu. Wspomniany ślad nazywa się feromonem. To dzięki tej właściwości mrówki są w stanie lokalizować trasy prowadzące do pokarmu.

Na rysunku 3.1 został przedstawiony graf z wierzchołkami A-B-C-D-E-F. Nad krawędziami kolorem czerwonym zostały oznaczone wagi. Na początku założmy, że mamy do dyspozycji 80 agentów. Przez N pierwszych iteracji mrówki poruszały się losowo i powstał następujący podział:

Tak jak można to zauważyć na grafice 3.2, po pierwszych iteracjach, przez obie ścieżki przechodzi taka sama liczba agentów. Dzieje się tak ponieważ mrówki rozpoczynają pracę w sposób losowy. W dalszych krokach następują modyfikacje i agenci dążą do wyznaczenia najoptymalniejszej ścieżki.




Rysunek 3.1: Położenie ścieżek na przykładowym grafie



Rysunek 3.2: Rozkład agentów na grafie po N początkowych iteracjach

Liczba agentów odwiedzających ścieżki zmienia się. Bardziej optymalna trasa zyskuje widoczną przewagę. W kolejnych iteracjach mrówki wykorzystują siłę feromonów. Bardziej optymalne ścieżki są częściej odwiedzane w związku z czym zapach na tych krawędziach jest silniejszy oraz podtrzymywany. Na mniej optymalnych trasach zapach zanika i przestają one być atrakcyjne dla agentów. Opisana sytuacja prowadzi do wyznaczenia trasy która jest najatrakcyjniejsza do przebycia dla mrówek.



Rysunek 3.3: Rozkład agentów w grafie po optymalizacji

3.3 Feromony

Feromony posiadają cechę która może się wydawać, że negatywnie wpływa na wyznaczanie ścieżki. Chodzi tutaj o ulatnianie się zostawionego zapachu. Na pierwszy rzut oka może się to zjawisko wydawać niepożądanym, ale w rzeczywistości ma duży wpływ na optymalizację. Jeśli feromony nie straciłyby na swojej sile, to bardzo prawdopodobne, że pierwotna ścieżka mogłaby zostać uznana za najbardziej optymalną.


W jaki sposób wyznaczona zostaje najbardziej optymalna ścieżka? Zapach feromonów jest podtrzymywany przez wędrujące mrówki. Z czasem owady te same zbaczają z drogi w celu poszukiwania alternatywnej trasy. Jeśli wybrana trasa jest optymalniejsza od pozostałych to ślad jest podtrzymywany, a na innych zanika. Dzięki temu w sposób iteracyjny można wyróżnić trasę najoptymalniejszą, a słabsze z czasem zostają odrzucone ponieważ przestają być odwiedzane.

Feromony są istotnym czynnikiem w całym procesie. To dzięki nim trasa jest ulepszana. Zapach posiada jedną z charakterystyk która na początku może wydawać się problematyczna. Wraz z upływem czasu siła zapachu słabnie aż do całkowitego zaniknięcia. Właściwość ta jest zaletą, a nie wadą. To dzięki pracy zespołowej zapach na najlepszej trasie jest podtrzymywany, a na słabszych zanika. Dzięki tej selekcji dłuższe trasy nie są brane pod uwagę w wyniku czego zostaje trasa najkorzystniejsza.

Do wyznaczenia optymalnej trasy potrzebne są długości jakie należy przebyć do przemieszczania się między punktami. W 3.1 przedstawione są przykładowe odległości.

Tabela 3.1: Wartości kosztów

| | A | B | C | D |
|---|---|---|---|---|
| A | 0 | 3 | 8 | 2 |
| B | 3 | 0 | 2 | 4 |
| C | 8 | 2 | 0 | 1 |
| D | 2 | 4 | 1 | 0 |




Rysunek 3.4: Graf z wagami

Równie ważne jest wyznaczenie początkowych współczynników feromonów. Na początku nadajmy wszystkim krawędziom w grafie wartości równe 1, a współczynnik parowania niech wynosi 0.5.

Tabela 3.2: Wartości feromonów

| | A | B | C | D |
|---|---|---|---|---|
| A | 0 | 1 | 1 | 1 |
| B | 1 | 0 | 1 | 1 |
| C | 1 | 1 | 0 | 1 |
| D | 1 | 1 | 1 | 0 |

Posiadając początkowe dane wyznaczmy w sposób losowy trasy dla dwóch agentów: L1 i L2. Agent L1 poruszał się trasą w której odwiedził wierzchołki w następującej kolejności: A, B, C, D, A.




Rysunek 3.5: Graf z początkowymi wartościami feromonów

Agent L2 wyznaczył następującą trasę: A, C, B, D, A.


Mrówki odpowiednio pokonały dystans 8 i 16 punktów. Dzięki tej informacji można zaktualizować wartości feromonów na poszczególnych krawędziach. Do obliczeń wykorzystany jest wzór: $\tau_{ij} = (1-p)\tau_{ij} + \sum_{k=1}^m \Delta\tau_{i,j}^k$. Krawędzie A-B i C-D zostały odwiedzone jedynie przez agenta L1 w wyniku czego wartość feromonu zostaje zmieniona na 10/16. Następnie krawędzie A-C i B-D zostają zaktualizowane na 9/16. Krawędzie A-D i B-C są odwiedzone dwukrotnie a wartość feromonów wynosi 11/16.

Ostatnią fazą algorytmu jest wyznaczenie prawdopodobieństwa z jakim kolejni agenci będą wybierać kolejny wierzchołek. W kolejnej iteracji agent L3 znajduje się w wierzchołku B. Do wyboru ma krawędzie A, C i D. Według wzoru $p_{ij} = \frac{(\tau_{ij})^\alpha (\eta_{ij})^\beta}{\sum (\tau_{ij})^\alpha (\eta_{ij})^\beta}$ wyliczane jest prawdopodobieństwo dla wszystkich możliwości. Przejście z krawędzi B do krawędzi A wynosi około 20%, do krawędzi D 30%, a do krawędzi C około 50%.


Optymalna trasa zostanie wykształcona po wykonaniu wielu iteracji. Ilość iteracji nie jest zdefiniowana i dla każdego przypadku może być różna. Sytuacja wygląda identycznie w przypadku wyboru wartości p. Ważne jest natomiast to, aby w trakcie działania algorytmu nie modyfikować tej wartości. Powinno ona być taka sama na każdym kroku algorytmu.



Rysunek 3.6: Trasa przebyta przez agenta L1



Rysunek 3.7: Trasa przebyta przez agenta L2



Rysunek 3.8: Graf z wartościami feromonów po modyfikacji

4. Algorytmy zachłanne

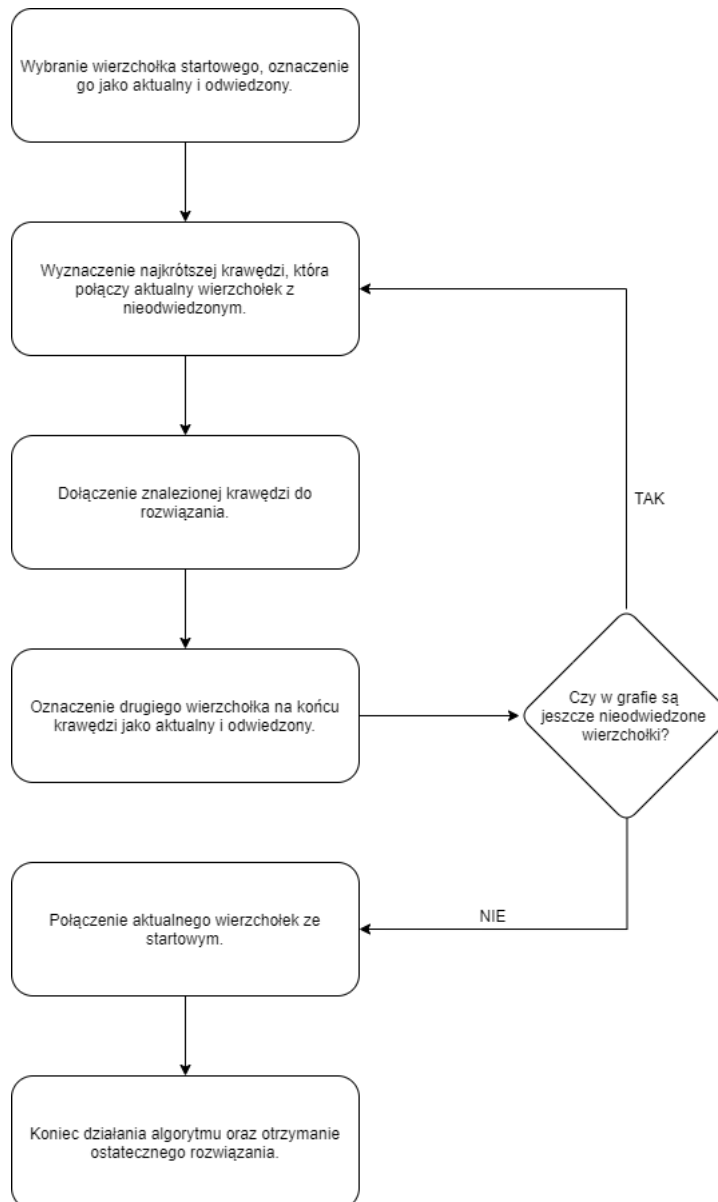
Istnieje wiele algorytmów zachłannych pozwalających otrzymać optymalne rozwiązanie dla problemu znalezienia najkrótszej trasy. W poniższym rozdziale opisane dokładnie zostało działanie algorytmu najbliższego sąsiada, algorytmu najmniejszej krawędzi oraz algorytmu a^* . W celu zoptymalizowania otrzymanych rozwiązań zastosowane zostaną operatory 2-opt oraz 3-opt.

4.1 Algorytm najbliższego sąsiada

Poniższy podrozdział przybliży działanie algorytmu najbliższego sąsiada. Wszystkie wymagane dla algorytmu operacje zostaną opisane krok po kroku oraz przedstawione na krótkim przykładzie. Jak sama nazwa wskazuje jest to algorytm polegający na odwiedzaniu, zaczynając od wybranego wierzchołka początkowego następnego wierzchołka znajdującego się najbliżej poprzednio odwiedzonego.


Na rysunku 4.1 został pokazany schemat blokowy algorytmu najbliższego sąsiada. Pierwszym krokiem jest wyznaczenie wierzchołka startowego. Następnie dla aktualnego wierzchołka należy obliczyć najkrótszą krawędź łączącą aktualny wierzchołek spośród kolekcji wierzchołków nieodwiedzonych. Wybór najlepszej opcji połączenia dwóch wierzchołków należy dodać do rozwiązania, a drugi wierzchołek staje się aktualnym od którego będziemy wyznaczać kolejne odległości do nieodwiedzonych jeszcze wierzchołków. Czynności należy powtarzać do momentu odwiedzenia wszystkich wierzchołków w podanym grafie. Na samym końcu wystarczy jedynie połączyć ostatni wierzchołek z początkowym. Po wykonaniu wszystkich kroków algorytm najbliższego sąsiada powinien zwrócić optymalne dla niego rozwiązanie.

Aby lepiej zobrazować otrzymanie rozwiązania przez algorytm przedstawiono poniżej na rysunku 5.1 jego działanie na przykładzie. W podanym przypadku należy założyć że wierzchołek nr 2 jest wierzchołkiem startowym, więc należy ustawić go jako aktualny w danym momencie. Po obliczeniu wszystkich odległości prowadzonych do wierzchołków nieodwiedzonych wychodzi, że najkrótsza krawędź prowadzi do wierzchołka nr 4, więc należy dołączyć wybrana krawędź do rozwiązania i oznaczyć nowy aktualny wierzchołek, który staje się również odwiedzionym. W podanym grafie znajdują się nadal nieodwiedzone wierzchołki, dlatego algorytm powtarza krok nr 2 w celu znalezienia kolejnej najkrótszej



Rysunek 4.1: Schemat algorytmu najbliższego sąsiada

krawędzi. Kolejną najlepszą odnaniezoną w danym momencie krawędzią, którą algorytm doda do rozwiązania będzie krawędź o wartości 3 łącząca aktualny wierzchołek z wierzchołkiem nr 5. Kroki 4, 5 oraz 6 przedstawiają kolejne powtarzalne iteracje algorytmu dochodząc w ostatnim kroku do utworzenia cyklu i tym zakończeniu działania algorytmu. W ten sposób otrzymano zachłanne rozwiązanie 2 - 4 - 5 - 3 - 1 - 2. Warto zaznaczyć, że dzięki oznaczaniu wierzchołków jako odwiedzony nie trzeba w żadnej iteracji martwić się o to czy dołączenie kolejnej krawędzi z nieodwiedzonym wierzchołkiem spowoduje utworzenie niepożądanego cyklu.

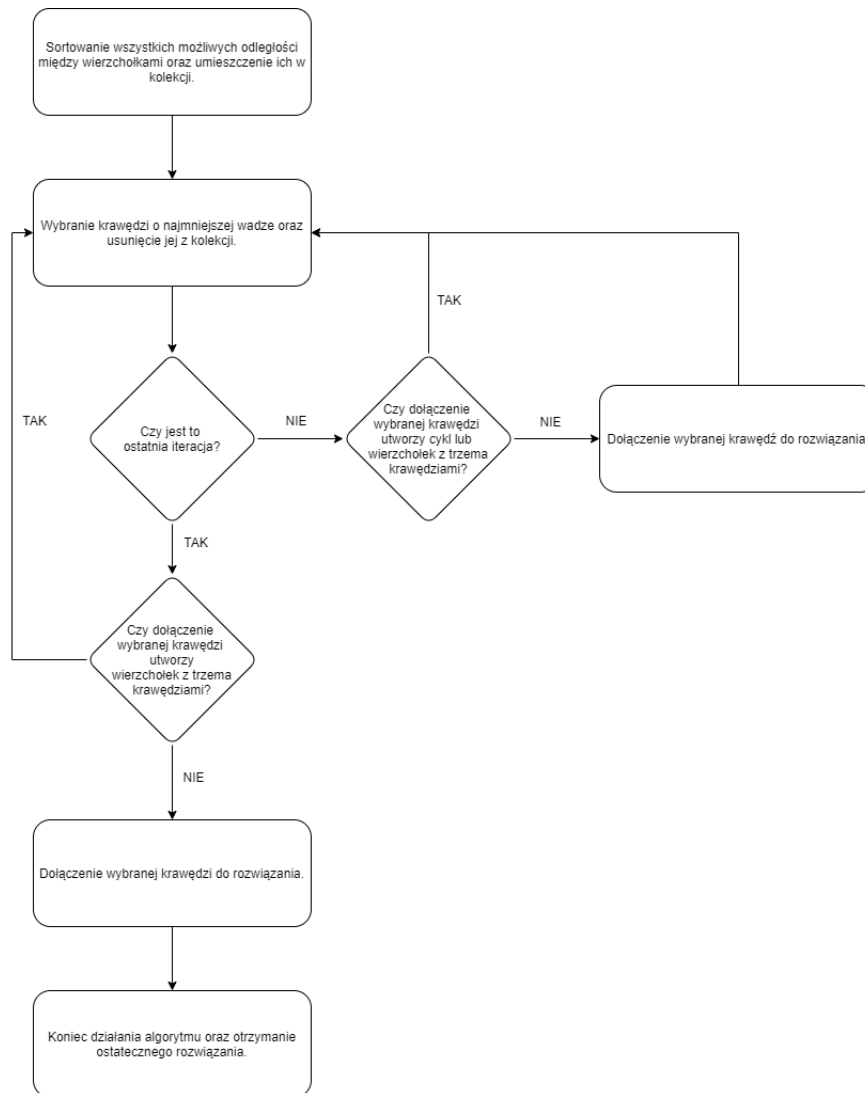


Rysunek 4.2: Algorytm najbliższego sąsiada

4.2 Algorytm najmniejszej krawędzi

Kolejny podrozdział algorytmów zachłannych został poświęcony dokładniejszemu opisowi działania algorytmu najmniejszej krawędzi, który w swoim działaniu przypomina algorytm poszukujący minimalnego drzewa rozpinającego, poprzez dołączenie do aktualnego rozwiązania najkrótszych wśród dopuszczalnych krawędzi. Aby otrzymać zachłanne rozwiązanie przy wykorzystaniu algorytmu najmniejszej krawędzi należy wykonać następujące kroki przedstawione schemacie blokowym na rysunku 4.3.

Algorytm rozpoczyna swoje działanie od posortowania wag krawędzi między wszystkimi wierzchołkami oraz umieszcza podane odległości w kolekcji. Następnie wybierana jest zawsze krawędź o najmniejszej wartości oraz od razu usuwana jest z podanej kolekcji. Aby wybrane połączenie między wierzchołkami zostało dodane do rozwiązania musi spełniać warunek nie utworzenia cyklu oraz wierzchołka o trzech krawędziach, w przeciwnym wypadku połączenie jest pomijane oraz algorytm wybiera kolejną krawędź. Iteracje są powtarzane do momentu, aż liczba dodanych połączeń jest równa liczbie wszystkich wierzchołków. W przypadku ostatniej iteracji wyznaczona krawędź nie musi już spełniać




Rysunek 4.3: Schemat algorytmu najmniejszej krawędzi


warunku z utworzeniem cyklu. Po zakończeniu działania algorytmu otrzymano optymalne rozwiązanie dla algorytmu najmniejszej krawędzi.

Działanie algorytmu przedstawione zostało na rysunku 4.4 przedstawiającym przykład ze sześcioma losowo rozmieszczonymi wierzchołkami. Natomiast wizualizacja kolejnych kroków algorytmu została przedstawiona na rysunku 4.5. Po posortowaniu wszystkich dostępnych krawędzi dla każdego wierzchołka można rozpocząć działanie algorytmu.

Podczas pierwszej iteracji okazuje się, że są aktualnie dwie krawędzie z najmniejszą wagą o wartości 3 (1 - 2 oraz 4 - 5), nie ma więc znaczenia, która krawędź algorytm doda w pierwszej kolejności, ponieważ żadna z wybranych nie utworzy w tym momencie cyklu. W przypadku drugiej iteracji algorytm wybiera krawędź o najmniejszej wadze, dołączając ją do aktualnego rozwiązania. Analogiczna sytuacja do pierwszej iteracji występuje w



Rysunek 4.4: Początkowe rozmieszczenie wierzchołków



Rysunek 4.5: Algorytm najmniejszej krawędzi

trzeciej iteracji, gdzie nie ma różnicy, która krawędź zostanie dołączona do rozwiązania. Czwarta iteracja pokazuje sytuację, w której nie można połączyć krawędzi 3 - 4, ponieważ utworzyłyby to niedozwolony w trakcie algorytmu cykl, dlatego tym razem wybierane jest inne połączenie o najmniejszej wadze (4 - 6). Kolejny krok przedstawia przypadek, gdzie nie jest możliwe połączenie krawędzi 2 - 4 (najmniejsza wartość - 7), ponieważ spowodowałoby dla wierzchołka nr 4 utworzenie trzech wychodzących z niego krawędzi, więc do rozwiązania dochodzi kolejna najmniejsza krawędź 1 - 6. W ostatnim kroku, pomimo dostępnych krawędzi z mniejszą wagą wybierana została krawędź 2 - 3, ponieważ tylko ona nie spowoduje utworzenia wierzchołka o trzech krawędziach. W takim wypadku kończąc działanie algorytmu otrzymano rozwiązanie 1 - 6 - 4 - 5 - 3 - 2 - 1.

4.3 Algorytm A*

Ostatnim omówionym rozwiązaniem do znajdowania najkrótszej ścieżki w grafie jest algorytm a^* , w którym zawsze zostanie znalezione najkorzystniejsze zachłanne rozwiązanie. Strategia gwarantuje, że każdy wierzchołek zostanie odwiedzony, przy czym dokonuje w danym momencie najlepszych wyborów. Dla struktur drzewiastych algorytm tworzy najlepsze rozwiązania. Główną zasadą algorytmu a^* jest minimalizacja funkcji kosztu oraz funkcji heurystycznej, gdzie ta ostatnia musi spełniać dwa wymagane warunki tj. warunek dopuszczalności i warunek monotoniczności. Warunek dopuszczalności polega na tym, aby funkcja heurystyczna za bardzo minimalizowała koszt, a przesadzała przy maksymalizacji zysku. Natomiast warunek monotoniczności mówi, że oszacowywanie wyniku musi być coraz mniej optymistyczne w momencie zbliżania się do rozwiązania. Jeśli przestrzeń przeszukiwań zawierać będzie ścieżki to można wówczas sprowadzić problem do problemu poszukiwania najkrótszej ścieżki w grafie. W danym przypadku funkcją heurystyczną będzie wówczas iloczyn liczby krawędzi do wybrania i najmniejsza wartość krawędzi. Zapewnia to w ten sposób, że taka funkcja jest nadmiernie optymistyczna.

<po badaniach powstanie tutaj schemat blokowy oraz przykład, tak jak w poprzednich algorytmach, ponieważ algorytm jest jeszcze dopracowywany>


4.4 Optymalizacja otrzymanych rozwiązań

W ostatnim podrozdziale skupimy się na sposobach optymalizacji otrzymanych przez algorytmy zachłanne rozwiązań. Dokładniej omówiona zostanie metoda 2-opt oraz metoda 3-opt.

4.4.1 Metoda 2-opt

Metoda optymalizacyjna 2-opt polega na pozbyciu się z cyklu dwóch krawędzi w celu zastąpienia ich innymi krawędziami w taki sposób, aby otworzyć zupełnie inny cykl. Iteracje można powtarzać dla każdej pary krawędzi, oprócz tych sąsiadujących ze sobą, ponieważ ich zamienienie nie przyniosłoby żadnej modyfikacji. Metoda nie ma na celu zmiany położenia wierzchołków, jedynie kolejności ich odwiedzania. Po wykonaniu całej optymalizacji, należy sprawdzić która modyfikacja przyniosła najlepszy efekt skrócenia długości cyklu. W przypadku jeżeli żadna modyfikacja nie dała lepszego rozwiązania, nie


należy modyfikować rozwiązania. Algorytm można wykonywać wielokrotnie, w ten sposób zostanie zrealizowane minimum lokalne. Dla lepszego przedstawienia działania metody 2-opt, należy spojrzeć na rysunek 5.4.



Rysunek 4.6: Metoda 2-opt

4.4.2 Metoda 3-opt

W odróżnieniu do algorytmu 2-opt, w metodzie 3-opt rozważane są wszystkie cykle, które można uzyskać wymieniając trzy krawędzie z cyklu aktualnego, przy czym jest możliwe wykonanie tego na wiele sposobów tak jak zostało to przedstawione na rysunku 5.5.



Rysunek 4.7: Metoda 3-opt

5. Zbiór danych

W latach 2017-2018, miasto Białystok było podzielone na sektory w których odpowiednia firma była odpowiedzialna za wywóz śmieci. Model ten był praktykowany przez wiele lat. Każda z firm we własnym zakresie decydowała o trasach jakie mają pokonywać ciężarówki w celu zebrania odpadów komunalnych. Cały proces składał się z wielu kroków i budził wiele zastrzeżeń. W związku z tym w 19 października 2018 roku został zorganizowany hackathon podczas którego zespoły zmierzyły się z przedstawionymi problemami.

Drużyny do dyspozycji miały zestaw danych z 2017 roku. Dane te były gromadzone przez podwykonawców. Zbiory z kluczowymi informacjami znajdowały się w arkuszach programu Microsoft Excel. Każdy z dokumentów odpowiadał danemu miesiącowi. Niestety nie każdy arkusz składał się z tych samych kolumn. Jednym z największych problemów była odpowiednia agregacja danych. W wielu arkuszach brakowało kluczowych kolumn.

Przykładowy miesięczny raport zawierał informację z datą zdarzenia, krótkim opisem oraz identyfikatorem pojemnika na odpady. Ważną informacją był również nr rejestracyjny pojazdu oraz współrzędne pojazdu. Raporty zawierały wiele innych informacji takich jak frakcja lub rodzaj MGO. W miesięcznym raporcie znajdowało się kilkadziesiąt tysięcy rekordów z takimi informacjami.

Dzięki informacjom takim jak data załadunku kontenera, numerze rejestracyjnym pojazdu oraz współrzędnych pojazdu istnieje możliwość odtworzenia trasy przejazdu przykładowej ciężarówki. Kluczowe jest znalezienie punktu początkowego oraz punktu rozładunku. Następnie chronologiczne połączenie dat załadunku dla danej ciężarówki pozwoli na odtworzenie trasy jaka została przebyta.

Analizując zbiory danych można zauważyć, że niektóre trasy zawierają więcej zdarzeń, inne mniej. Aby sprawdzić jak efektywny jest dany algorytm zostały wybrane trzy trasy. Pierwsza trasa składa się z 111 punktów, druga z 150, a trzecia z 248. Dla każdej z wariacji została zmierzona droga jaką przebyła ciężarówka.

Do obliczeń odległości pomiędzy kontenerami zostało wykorzystane API udostępnione przez amerykańską spółkę Google LLC. Aby odpowiednio skorzystać z udostępnionej funkcjonalności należy przygotować zapytanie. Jako parametry wejściowe konieczne jest przekazanie współrzędnych dwóch punktów. W odpowiedzi API znajduje się informacja o

odległości pomiędzy punktami. Wykorzystując udostępnione rozwiązanie można wyznaczyć odległości pomiędzy wszystkimi lokalizacjami zbiórki odpadów.

6. Badania

W tym rozdziale zostaną przedstawione wyniki optymalizacji dla tras przedstawionych w poprzednim rozdziale. Każda trasa została przedstawiona w oddzielnych podrozdziałach. W tabelach tła komórek z wartościami przebytego dystansu zostały zmienione w zależności od spełnianego warunku. Kolorem jasno-żółtym są oznaczone wartości które są większe od oryginalnej trasy. Kolorem żółtym zostały oznaczone pole które są najlepsze dla przedstawionych parametrów. Najlepszy wynik został oznaczony kolorem zielonym.

Algorytm genetyczny został zbadany dla trzech różnych wartości populacji N : 100, 1000 oraz 2000; czterech różnych wartości iteracji (pokoleń): 100, 1000, 2000 oraz 4000. Dla każdej wariacji tych parametrów zostało zbadane krzyżowanie PMX, OX oraz CX, z różnymi kombinacjami mutacji: wstawiająca - insert, zamieniająca - swap oraz odwracająca - revert. Współczynnik mutacji dla wszystkich uruchomień wynosi 0.1. Dla każdej wariacji parametrów wejściowych algorytm został uruchomiony dziesięć razy. W tabelach dotyczących wyników algorytmu genetycznego, zostały przedstawione agregowane dane.

Jednym z parametrów wejściowych algorytmu mrówkowego jest współczynnik parowania feromonów. To dzięki temu parametrowi wybierane są optymalne trasy, a te gorsze odrzucane. Ich wartości są wyrażane procentowo w zakresie od 1% do 99%. Dla każdej trasy została wybrane takie same wartości. Pomiar wyników został rozpoczęty od wartości 10%. W każdym korku wartość ta była zwiększana o kolejne 10% aż do 90%. Kolejnym istotnym parametrem jest ilość iteracji. Parametr ten oznacza ile razy mrówki mrówki mają wykonywać ulepszenie trasy. Do badań zostały dobrane trzy wartości: 50, 75, 100. Parametr ten ma bezpośredni wpływ na optymalizację ale również na czas jaki algorytm potrzebuje na wykonanie wszystkich operacji.

6.1 Trasa I

Pierwsza trasa składa się ze 111 punktów, odwiedzonych przez pojazd. Długość oryginalna tej trasy wynosi 48897 metrów.

Tabela 6.1: Trasa I - średnie wyniki algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 91502 | 96029 | 105868 | 102746 | 109380 | 115816 | 97015 | 112795 | 116291 |
| 100 | 1000 | 52959 | 67241 | 80988 | 58800 | 70722 | 93124 | 55599 | 67370 | 92538 |
| 100 | 2000 | 49747 | 61007 | 80468 | 52822 | 64938 | 89324 | 51134 | 61108 | 86920 |
| 100 | 4000 | 49368 | 59649 | 79494 | 50284 | 62967 | 98000 | 48571 | 57028 | 85739 |
| 1000 | 100 | 55008 | 67898 | 56269 | 64427 | 63525 | 69052 | 49959 | 53471 | 58104 |
| 1000 | 1000 | 37347 | 42081 | 49527 | 41809 | 46600 | 60650 | 33768 | 37948 | 50090 |
| 1000 | 2000 | 39158 | 40581 | 50985 | 40903 | 45041 | 64489 | 33843 | 38791 | 48072 |
| 1000 | 4000 | 37951 | 42112 | 50359 | 40036 | 47795 | 62245 | 34961 | 37842 | 49857 |
| 2000 | 100 | 51624 | 48902 | 49112 | 62336 | 61150 | 57542 | 40969 | 44643 | 42287 |
| 2000 | 1000 | 36492 | 39233 | 43081 | 38086 | 45761 | 53166 | 32571 | 35453 | 39076 |
| 2000 | 2000 | 36410 | 40379 | 40711 | 39554 | 41320 | 52030 | 32326 | 35353 | 40382 |
| 2000 | 4000 | 35406 | 38159 | 42454 | 39145 | 44137 | 51350 | 32667 | 34999 | 48295 |

6.1.1 Wyniki algorytmu genetycznego

W tabeli 6.1 zostały przedstawione średnie wyniki dla każdej kombinacji parametrów. Kolorem żółtym zostały oznaczone wyniki lepsze od długości oryginalnej. Kolorem pomarańczowym najlepszy wynik dla danego N i k, a kolorem zielony najlepszy globalny wynik. Na pierwszy rzut oka widać, że wraz ze wzrostem parametru N osiągane były lepsze wyniki. Dla populacji wynoszącej 100 osobników, tylko dla krzyżowania CX i mutacji Insert przy 4000 iteracjach osiągnięto średni wynik lepszy od oryginału. Przy mniejszej wartości k, najlepszy wynik osiągnęło krzyżowanie PMX. Dla N = 1000 lepszych wyników było już więcej. Zarówno dla krzyżowania PMX, OX oraz CX. Gdzie zawsze najlepszy wynik osiągany był dla krzyżowania CX i mutacji Insert. Dla tej kombinacji udało się zoptymalizować trasę do około 34 kilometrów. Najslabiej wypadła mutacja revert, tylko w jednym przypadku udało się dla niej poprawić wynik. Dla N=2000, k=2000 oraz krzyżowaniu CX i mutacji insert został osiągnięty najlepszy wynik globalny 32326 metrów. Widać również, że od k = 1000 dla wszystkich parametrów z wyjątkiem krzyżowania OX oraz mutacji Revert udało się osiągnąć wynik lepszy od oryginału. Przy wszystkich krzyżowaniach najslabiej sobie poradziła mutacja Revert.

W tabeli 6.2 została przedstawiona procentowa ilość wyników lepszych od długości trasy oryginalnej. Widać, że od N = 1000 oraz k = 1000 dopiero udało się osiągnąć 100 procent skuteczności, dla niektórych krzyżowań i mutacji. Najslabiej sobie radząca mutacja Revert, jest jedyną mutacją, jaka osiągnęła wszystkie wyniki lepsze od oryginału dla N = 2000, k = 100 oraz dla krzyżowania CX.

Tabela 6.2: Trasa I - tbd algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX | PMX | PMX | OX | OX | OX | CX | CX | CX |
|------|------|--------|------|--------|--------|------|--------|--------|------|--------|
| | | Insert | Swap | Revert | Insert | Swap | Revert | Insert | Swap | Revert |
| 100 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 1000 | 30% | 0% | 0% | 0% | 0% | 0% | 10% | 0% | 0% |
| 100 | 2000 | 50% | 0% | 0% | 30% | 0% | 0% | 30% | 0% | 0% |
| 100 | 4000 | 40% | 0% | 0% | 40% | 0% | 0% | 50% | 10% | 0% |
| 1000 | 100 | 10% | 0% | 0% | 0% | 0% | 0% | 80% | 20% | 10% |
| 1000 | 1000 | 100% | 100% | 50% | 100% | 90% | 0% | 100% | 100% | 30% |
| 1000 | 2000 | 100% | 100% | 30% | 100% | 90% | 0% | 100% | 100% | 60% |
| 1000 | 4000 | 100% | 100% | 40% | 100% | 60% | 0% | 100% | 100% | 50% |
| 2000 | 100 | 30% | 40% | 50% | 0% | 0% | 0% | 90% | 80% | 100% |
| 2000 | 1000 | 100% | 100% | 90% | 100% | 70% | 20% | 100% | 100% | 90% |
| 2000 | 2000 | 100% | 100% | 100% | 100% | 100% | 40% | 100% | 100% | 100% |
| 2000 | 4000 | 100% | 100% | 100% | 100% | 100% | 40% | 100% | 100% | 100% |

Tabela 6.3: Trasa I - najlepsze wyniki algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX | PMX | PMX | OX | OX | OX | CX | CX | CX |
|------|------|--------|-------|--------|--------|-------|--------|--------|--------|--------|
| | | Insert | Swap | Revert | Insert | Swap | Revert | Insert | Swap | Revert |
| 100 | 100 | 80385 | 87226 | 81154 | 90764 | 99185 | 101137 | 72268 | 103408 | 92859 |
| 100 | 1000 | 45076 | 62481 | 67443 | 53948 | 60699 | 78382 | 45134 | 56918 | 79955 |
| 100 | 2000 | 40964 | 53316 | 70100 | 45500 | 55396 | 80719 | 43142 | 54430 | 79636 |
| 100 | 4000 | 44853 | 52397 | 69287 | 40628 | 56153 | 91440 | 41805 | 45953 | 72035 |
| 1000 | 100 | 45769 | 59523 | 50232 | 56634 | 58272 | 62965 | 40804 | 42391 | 41647 |
| 1000 | 1000 | 34630 | 36034 | 42016 | 39283 | 44320 | 53480 | 32433 | 35227 | 37569 |
| 1000 | 2000 | 35051 | 36704 | 45852 | 35709 | 41317 | 57478 | 32334 | 35576 | 39953 |
| 1000 | 4000 | 33268 | 37649 | 44333 | 35718 | 41883 | 49322 | 33089 | 34642 | 40220 |
| 2000 | 100 | 44493 | 42497 | 42138 | 56466 | 56884 | 52010 | 36349 | 38830 | 38461 |
| 2000 | 1000 | 33609 | 36100 | 37047 | 34801 | 38625 | 40817 | 30939 | 33284 | 36203 |
| 2000 | 2000 | 33257 | 36216 | 37967 | 34591 | 36458 | 47022 | 31118 | 32798 | 36203 |
| 2000 | 4000 | 31347 | 36834 | 40193 | 34269 | 37693 | 43242 | 31118 | 33245 | 35271 |

W tabeli 6.3 zostały pokazane najlepsze wyniki, czyli wartość minimalna dla każdego z 10 wywołań algorytmu dla danych parametrów. Dla N=100 w przypadku dwóch krzyżowań PMX, CX oraz mutacji Insert zostały osiągnięte najlepsze wyniki lepsze od oryginału, nie udało się tego osiągnąć jedynie dla k = 100. Gdy liczba osobników wynosiła 1000, przy większości parametrów udało się osiągnąć wynik lepszy niż oryginał. Dla N = 2000 tylko krzyżowanie OX przy 100 iteracjach, ani razu nie osiągnęło wyniku lepszego od oryginału. Dla wszystkich innych kombinacji parametrów udało się poprawić rozwiązanie. Najlepszy globalny wynik został znaleziony dla N = 200, k = 100, krzyżowaniu CX oraz mutacji Insert i wyniósł 30939 metrów. Od N = 100 i k = 4000 zawsze najlepszy wynik wystąpił dla krzyżowania CX i mutacji Insert.

W tabeli 6.4 zostały przedstawione średnie czasy wywołań. Kolorem pomarańczowym zostały zaznaczone najlepsze średni czasy dla danego N i k. Tylko w dwóch przypadkach najszybsze nie było kzyżowanie CX oraz mutacja Revert. Gdzie dla N = 2000 oraz k =

Tabela 6.4: Trasa I - średnie czasy wykonywania algorytmu dla danych parametrów wejściowych

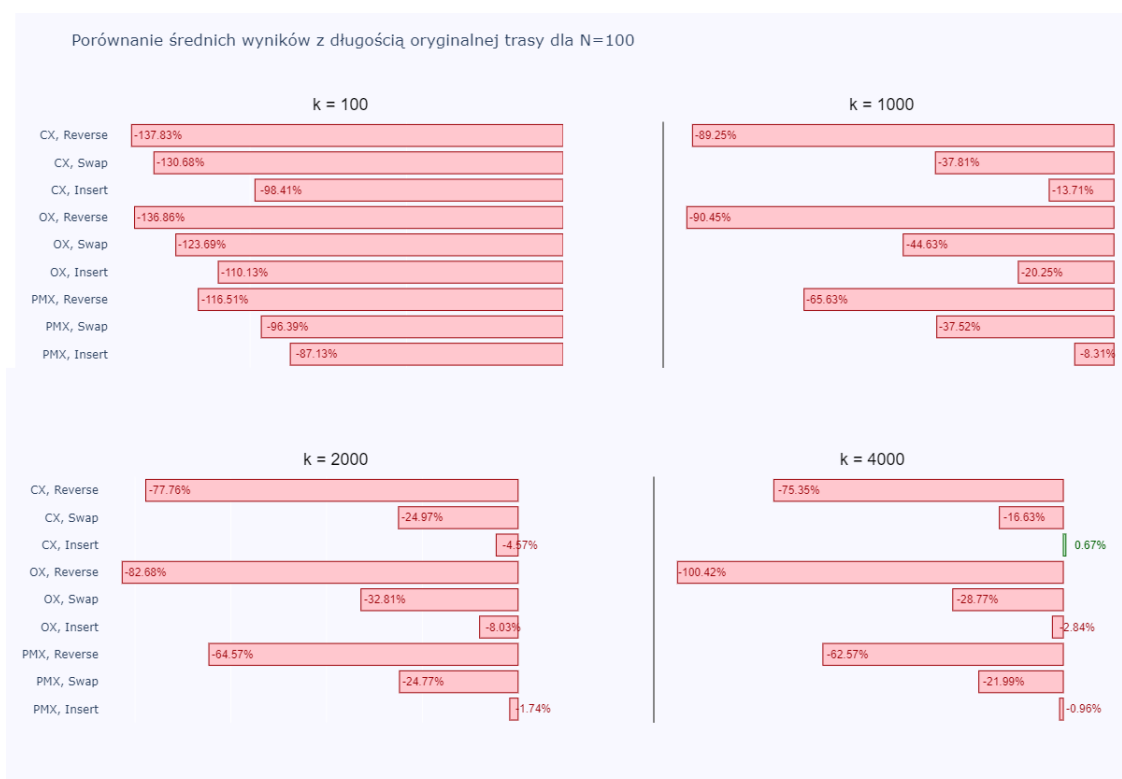
| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 0,03 | 0,03 | 0,02 | 0,02 | 0,02 | 0,02 | 0,02 | 0,01 | 0,01 |
| 100 | 1000 | 0,19 | 0,19 | 0,18 | 0,15 | 0,15 | 0,14 | 0,15 | 0,12 | 0,12 |
| 100 | 2000 | 0,37 | 0,36 | 0,34 | 0,29 | 0,28 | 0,27 | 0,28 | 0,24 | 0,23 |
| 100 | 4000 | 0,70 | 0,70 | 0,71 | 0,60 | 0,58 | 0,55 | 0,53 | 0,49 | 0,47 |
| 1000 | 100 | 0,35 | 0,53 | 0,34 | 0,24 | 0,23 | 0,26 | 0,22 | 0,21 | 0,23 |
| 1000 | 1000 | 2,31 | 2,34 | 2,34 | 1,99 | 1,92 | 1,84 | 1,76 | 1,70 | 1,71 |
| 1000 | 2000 | 4,51 | 4,57 | 4,62 | 3,77 | 3,86 | 3,60 | 3,42 | 3,38 | 3,21 |
| 1000 | 4000 | 8,88 | 9,10 | 8,81 | 7,38 | 7,46 | 7,36 | 6,72 | 6,65 | 6,23 |
| 2000 | 100 | 0,80 | 0,80 | 0,79 | 0,59 | 0,58 | 0,57 | 0,61 | 0,55 | 0,54 |
| 2000 | 1000 | 5,64 | 5,58 | 5,37 | 4,48 | 4,44 | 4,32 | 4,12 | 3,96 | 3,88 |
| 2000 | 2000 | 10,22 | 10,28 | 10,23 | 9,02 | 8,96 | 8,79 | 8,33 | 8,02 | 7,86 |
| 2000 | 4000 | 20,77 | 20,85 | 20,83 | 17,74 | 17,98 | 17,99 | 16,06 | 15,74 | 7,26 |

4000, algorytm średnio dla tych parametrów wykonywał się dwa razy szybciej od innych. Najlepsze średni wynik długości trasy dla $N = 1000$ wyniósł 33843 metrów było to przy 1000 iteracjach, a dla $N = 2000$ osiągnięto najlepszy globalny wynik 32326 przy 200 iteracjach (Tab. 6.1). Średni wynik poprawił się o ponad kilometr, lecz czas wykonania wzrósł z 3.42 sekundy do 8.79 sekund. Dla $k = 4000$ średni wynik długości był gorszy, a czas wykonania algorytmu wzrósł już do 16.06 sekundy. Krzyżowanie CX dla $N = 1000$ oraz $k = 1000$ wykonuje się dla trasy pierwszej poniżej 2 sekund. W tym czasie znajduwane jest rozwiązanie średnio lepsze o 8 kilometrów od trasy oryginalnej przy mutacji Insert. Dla krzyżowania CX, $N = 1000$ oraz $k = 100$ znaleziono średnie rozwiązanie lepsze, niż trasa oryginalna w czasie poniżej 1 sekundy.

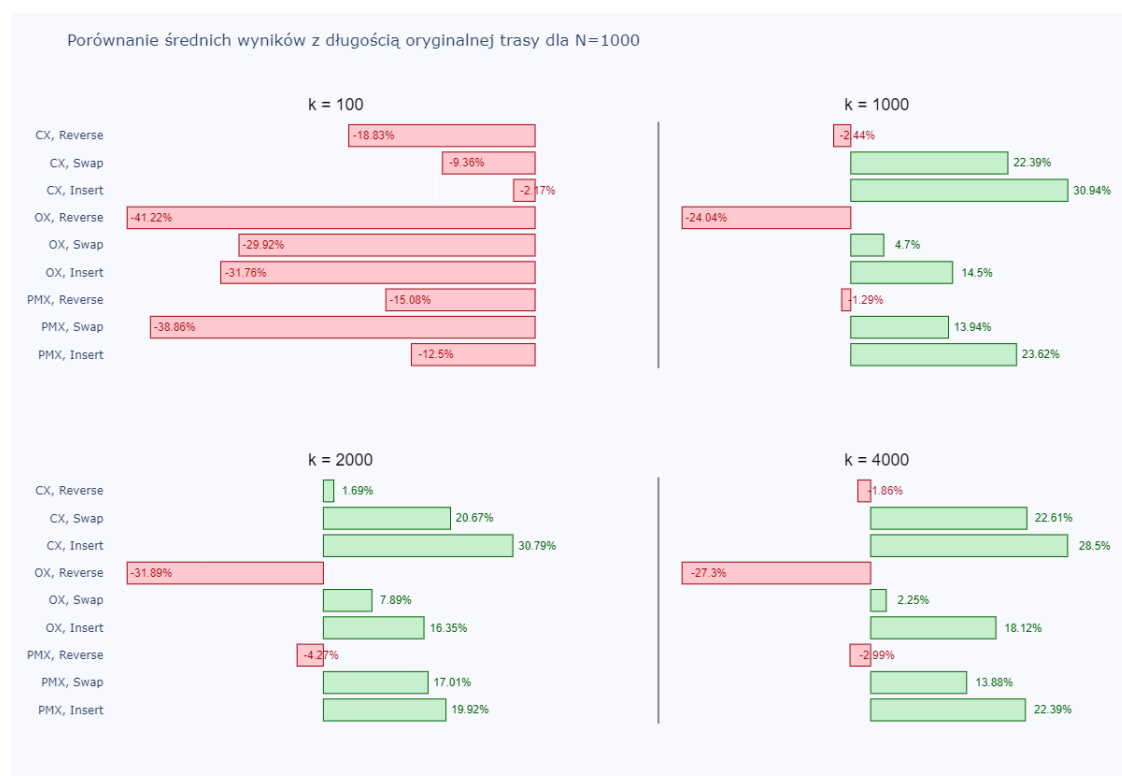
Rysunki 6.1, 6.2 oraz 6.3 przedstawiają wykresy, które porównują o ile różni się rozwiązanie od długości trasy oryginalnej, kolejna dla $N=100$, $N=1000$ oraz $N = 2000$. Widać, że wraz ze wzrostem N , następuje poprawa wyników. Dla $N = 1000$ udało się zoptymalizować trasę powyżej 25 procent, w dwóch przypadkach było to nawet powyżej 30. Natomiast dla $N = 2000$ oraz $k > 100$, każda wariacja parametrów optymalizowała rozwiązanie o kilkanaście procent, z wyjątkiem krzyżowania OX i mutacji Reverse.

6.1.2 Wyniki algorytmu mrówkowego


Algorytm został uruchomiony dziesięciokrotnie dla każdej możliwej wariacji parametrów wejściowych. W odpowiedzi program przedstawił w odpowiedniej kolejności punkty jakie zostały zawarte w rozwiązaniu, przebyty dystans oraz czas wykonania algorytmu. Z zebranych danych została wyliczona średnia, został wyznaczony najlepszy wynik oraz



Rysunek 6.1: Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=100



Rysunek 6.2: Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=1000



Rysunek 6.3: Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=2000

wyliczono sumę punktów których łączny przebyty dystans jest krótszy od oryginału. Przy wykorzystaniu tych miar można wykonać porównanie z oryginalną trasą przebytą w rzeczywistości przez ciężarówkę.

Każda z tabel przedstawiająca wynik algorytmu mrówkowego składa się z takiej samej ilości kolumn oraz wierszy. W kolumnie z oznaczeniem k została zaprezentowana ilość przeprowadzonych iteracji. Wartości te zaczynają się od 50 i są zwiększane co 25 do 100. Każda kolumna przedstawia współczynnik parowania feromonów. Wartości te zaczynają się od 0.1 i są zwiększane co 0.1 do 0.9.

Najlepsze wyniki algorytmu mrówkowego dla trasy numer 1 zostały przedstawione w tabeli ???. Spośród najlepszych wyników dla danej wariacji, żadna próba nie została sklasyfikowana jako gorsza od oryginalnej odległości. Najgorszy wynik wystąpił dla najniższej wartości iteracji oraz najniższego współczynnika parowania. Ta trasa nadal jest lepsza od oryginalnej o 7 439 metrów. Najlepsza wartość jaką udało się osiągnąć to 27131. Jest to wartość jaka została osiągnięta dla 75 ilości iteracji oraz dla współczynnika parowania wynoszącego 0.4. W najlepszym wypadku trasa została ulepszona o około 55%.

Tabela 6.5: Trasa I - najlepsze wyniki algorytmu mrówkowego dla danych parametrów wejściowych

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 41458 | 27288 | 27554 | 27257 | 32569 | 27297 | 30815 | 29160 | 32499 |
| 75 | 28137 | 27998 | 27583 | 27131 | 29459 | 29298 | 27332 | 36046 | 32471 |
| 100 | 27259 | 28194 | 27606 | 27490 | 27193 | 34429 | 37313 | 35244 | 31738 |

W tabeli numer ?? znajdują się średnie wyniki z dziesięciu pomiarów dla takich samych parametrów. Najlepsze wyniki występują dla współczynnika parowania znajdującego się w zakresie od 0.1 do 0.4 i oscylują poniżej progu 40 000 metrów. Wyjątkiem jest jedynie współczynnik parowania równy 0.1 jeśli zostało wykonanych 50 iteracji. W tym przypadku wartość jest większa od oryginalnej i wynosi 50 543. Na tym przykładzie można świetnie zauważyć jak istotna jest ilość iteracji jaka zostanie wykonana. W kolejnych krokach ilość iteracji była zwiększana, a średnia odległość ulegała poprawie. Dla stu iteracji odnotowano najlepszą średnią równą 29 479.

Tabela 6.6: Trasa I - średnie wyniki algorytmu mrówkowego dla danych parametrów wejściowych

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 50543 | 30430 | 33453 | 35171 | 42787 | 41658 | 45557 | 44527 | 44370 |
| 75 | 32810 | 30993 | 33539 | 31485 | 44500 | 44022 | 45114 | 48684 | 46820 |
| 100 | 29479 | 34264 | 31697 | 39139 | 41934 | 47499 | 49393 | 47152 | 46382 |


Istotnym parametrem jaki należy wziąć pod uwagę jest to, jak często algorytm jest w stanie poprawić oryginalną trasę. W tym celu została stworzona tabela numer ?. Możemy zauważyć z jaką skutecznością program jest w stanie poprawić trasę. Wyniki potwierdzają wcześniejsze wnioski. Najlepsze wyniki można zestawić ze współczynnikiem parowania feromonów z zakresu od 0.1 do 0.4. Co więcej dla ilości iteracji równej 75 dla każdego ze współczynników trasa została polepszona.

Tabela 6.7: Trasa I - suma lepszych tras w porównaniu do oryginalnej

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|------|------|------|------|-----|-----|-----|-----|-----|
| 50 | 50% | 100% | 100% | 100% | 80% | 80% | 60% | 70% | 80% |
| 75 | 100% | 100% | 100% | 100% | 60% | 40% | 60% | 40% | 60% |
| 100 | 100% | 100% | 100% | 80% | 70% | 60% | 20% | 40% | 70% |

Na wykresie 6.6 przedstawione zostało procentowe porównanie średniej wartości dla każdego współczynnika parowania i wartości k równej 50. Z wykresu można odczytać,

że algorytm mrówkowy w najgorszym wygenerował trasę o 3.37% gorszą od oryginalnej. Pozostałe przypadki pokazują jednak, że profit optymalizacji jest wyższy od tego spadku. Trasa została poprawiona o 37.77%.




Rysunek 6.4: Procentowy rozkład średnich wartości dla 50 iteracji

Na wykresie ?? zwiększona została ilość iteracji do 75. Dzięki tej aktualizacji średnie wyniki są większe od pierwotnej długości trasy. Warto odnotowania jest również to, że wcześniej najgorsza wartość jest teraz jedną z najlepszych. Różnica 25 iteracji przełożyła się na poprawę o 36.27%. Współczynniki z zakresu 0.2 0.4 w dalszym ciągu przekładają się na najwyższe średnie wyniki.

Najwyższa średnia optymalizacja została odnotowana dla 100 iteracji oraz współczynnika parowania wynoszącego 0.1. Na uwagę zasługuje fakt iż średnia długość trasy dla tego współczynnik przy 50 iteracjach był najgorszą średnią. Na wykresie ?? można zauważyć rozkład wszystkich współczynników.

Porównanie średnich wyników z długością oryginalnej trasy.

k = 75



Rysunek 6.5: Procentowy rozkład średnich wartości dla 75 iteracji


Oprócz samych prac nad optymalizacjami należy zwrócić uwagę z jaką szybkością algorytm jest w stanie przedstawić rozwiązanie. W tabeli ?? przedstawiony jest średni czas wykonania algorytmu. Oczywiście wydaje się, że wraz ze wzrostem ilości wykonanych iteracji wzrasta czas wykonania programu. Średnio dla programu z ilością iteracji równą 50 czas oczekiwania wynosił blisko 13 sekund. Dla 75 iteracji było to 21.732 sekundy, a dla 100 31.547. Zestawiając wyniki czasowe z procentowymi wartościami tras jakie zostały wyprodukowane przez program, można zauważyć, że ilość większa ilość iteracji nie musi oznaczać optymalizacji trasy.

Tabela 6.8: Trasa I - średnie wyniki czasu wykonania algorytmu mrówkowego dla parametru ilości iteracji

| | | | |
|----------|--------|--------|--------|
| iteracje | 50 | 75 | 100 |
| czas | 12.945 | 21.732 | 31.547 |

Porównanie średnich wyników z długością oryginalnej trasy.

k = 100



Rysunek 6.6: Procentowy rozkład średnich wartości dla 100 iteracji

6.1.3 Wyniki algorytmów zachłannych

6.1.4 Porównanie algorytmów

Najlepsze wyniki algorytmów nie są takie same. Wszystkie z wyników są lepsze od oryginalnej trasy. Algorytm genetyczny wygenerował najlepszy wynik równy 30939. Jest to wynik o 37% lepszy od pierwotnej trasy. Taki wynik udało się otrzymać w 4.12 sekundy. Algorytm mrówkowy wygenerował trasę o łącznej długości 27131 metrów co jest lepszym wynikiem od poprzedniego algorytmu. Oryginalna trasa została poprawiona o 45%. Czas jaki był potrzebny na polepszenie ścieżki to 21.73 sekundy. Czas oczekiwania jest więc dłuższy od czasu jaki potrzebuje algorytm genetyczny. Najlepsza trasa, którą uzyskały algorytmy zachłanne wynosiła 30205 metrów, a po optymalizacji metodą 2-opt

trasa zmniejszyła się do 29 965 metrów. Wynik ten jest o 39% lepszy od trasy początkowej. Wynik taki udało się otrzymać w 5.22 sekund.

Najgorszy wynik został wygenerowany przez algorytm genetyczny. Trasa ta została jednak wyznaczona w najlepszym czasie. Nieco krótszą trasę wyznaczył algorytm A*. Czas jaki był potrzebny na osiągnięciu takiego wyniku był nieco gorszy od poprzedniego algorytmu. Najlepsza trasa została uzyskana przy użyciu algorytmu mrówkowego. Jednak czas na otrzymanie takiego wyniku był dużo dłuższy od wcześniej wymienionych rozwiązań.

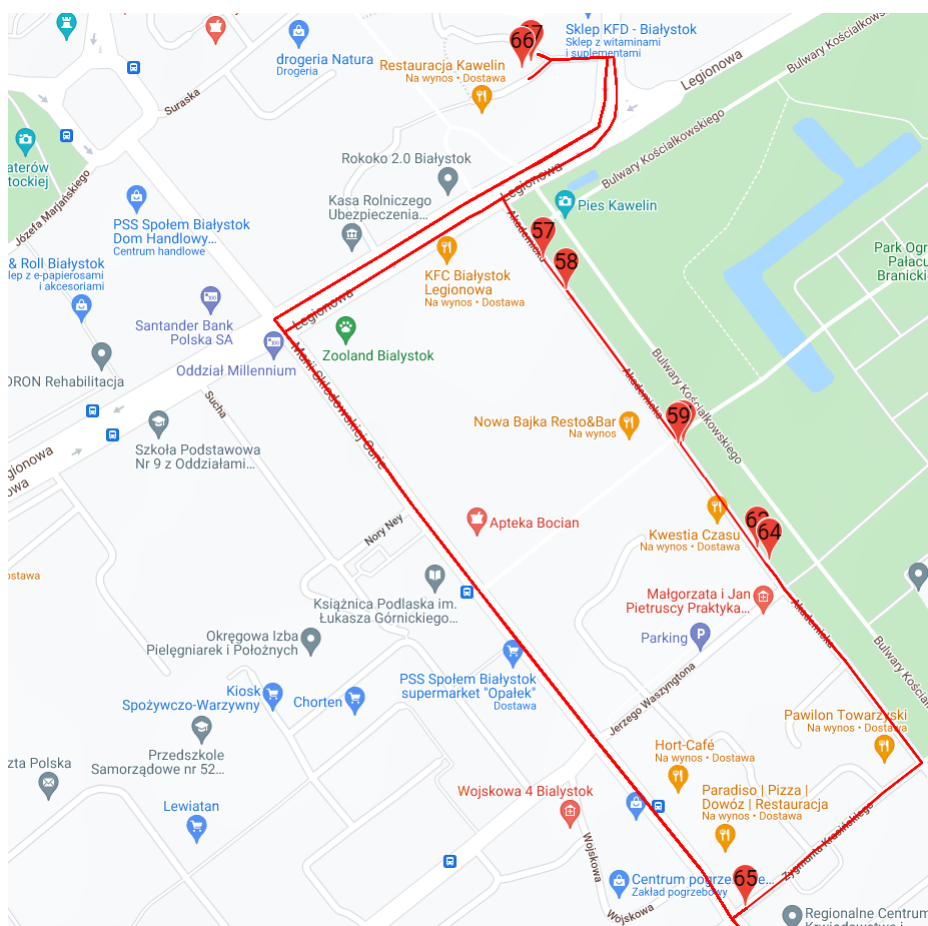
Na zdjęciach 6.7, 6.8, 6.9 zostały pokazane przykładowe różnice w wygenerowanych trasach przez algorytmy. Różnice te dotyczą kolejności odwiedzania punktów dla takiego samego odcinka trasy. Liczba znajdująca się w treści markera oznacza kolejność odwiedzanych punktów (punkt w jakim znajduje się kontener z odpadami komunalnymi). Na rysunku 6.8 został pokazany fragment trasy wygenerowanej przez algorytm mrówkowy. Można zauważyć, że jest to również początkiem trasy tego algorytmu. Porównując algorytm genetyczny 6.7 w tym samym miejscu, można zauważyć, że wierzchołki te są odwiedzane dopiero w połowie trasy. Trasa dla algorytmu mrówkowego i algorytmu A* jest bardzo podobna. Jediną różnicą na tym odcinku jest kolejność wybrania 3 punktu przez algorytm mrówkowy. W algorytmie A* punkt ten został odwiedzony jako 11.

6.2 Trasa II

Druga trasa składa się ze 150 punktów, odwiedzonych przez pojazd. Długość oryginalna tej trasy wynosi 40402 metrów.

6.2.1 Wyniki algorytmu genetycznego

W tabeli 6.9 zostały pokazane średnie wyniki dla danych parametrów. Na pierwszy rzut oka widać, że w przeciwieństwie do poprzedniej trasy, nie zawsze krzyżowanie CX oraz mutacja Insert dała najlepsze wyniki. Dla $N = 2000$ oraz $k = 100$ najlepszy średni wynik osiągnęło krzyżowanie CX z mutacją Revert, a dla $N = 2000$ i $k = 2000$ lub $k = 4000$ najlepsze wyniki były dla krzyżowania CX oraz mutacji Swap. Widać również, że poprawa względem oryginalnej trasy nastąpiła dla niektórych parametrów krzyżowań i mutacji dopiero od $N = 1000$ oraz $k = 1000$. Dla mniejszych wartości nie udało się zoptymalizować rozwiązań. Przy $N = 1000$, trasę udało się poprawić średni o około 10 kilometrów. Natomiast najlepszy wynik globalny osiągnięto dla $N = 2000$ oraz $k = 1000$,

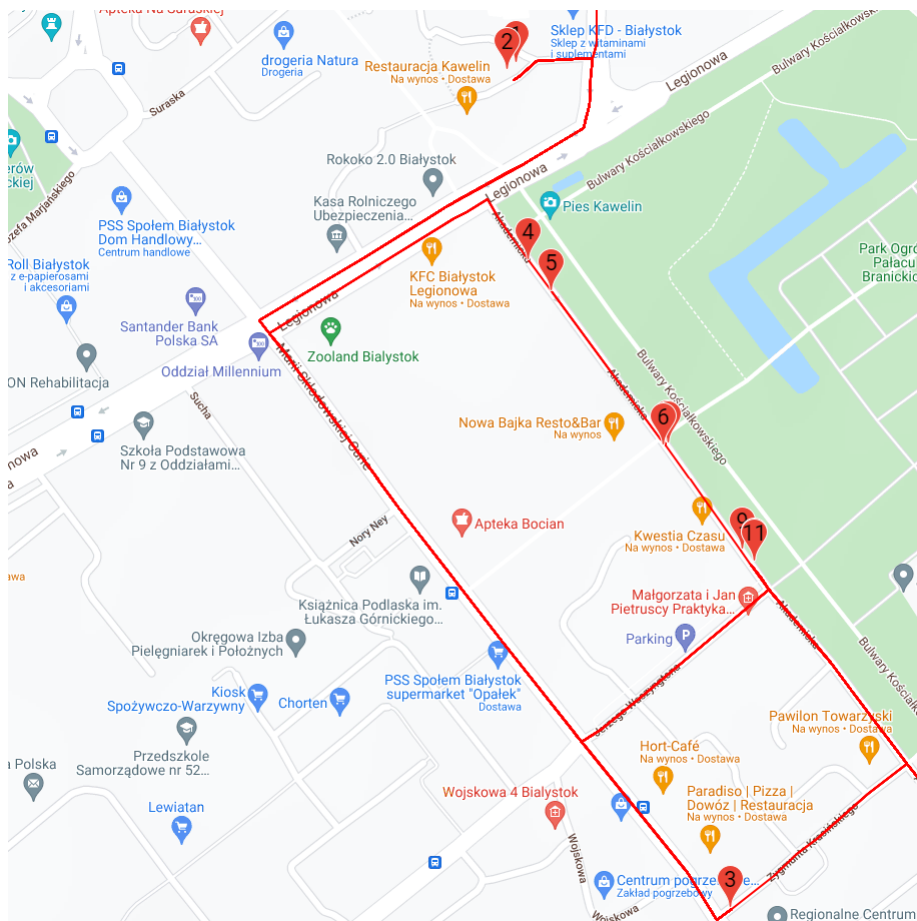


Rysunek 6.7: Fragment trasy algorytmu genetycznego

krzyżowanie CX z mutacją Insert i było to 28196 metrów. Czyli poprawa prawie o 12 kilometrów. Mutacja Revert ani razu nie zoptymalizowała wyniku dla krzyżowania PMX oraz OX.

W tabeli 6.10 została przedstawiona procentowa ilość wyników lepszych od długości trasy oryginalnej. Dla $N = 2000$ i $k = 1000$ lub $k = 4000$, wszystkie wyniki niezależnie od mutacji były zoptymalizowane dla krzyżowania CX. Dla $N = 100$ praktycznie w ogóle nie udało się zoptymalizować rozwiązania, poza pojedynczymi przypadkami dla $k = 4000$. Krzyżowanie OX miało 100 procent skuteczności od $N = 2000$ oraz $k = 2000$. Krzyżowanie OX z mutacją Revert, ani razu nie znalazło lepszego rozwiązania od trasy oryginalnej.

W tabeli 6.11 są pokazane najlepsze wyniki algorytmu genetycznego dla trasy II. Dla $N = 1000$ i $N = 2000$, najlepsze wyniki dla poszczególnych wartości k osiągały te same kombinacje krzyżowania i mutacji. Tak dla $k = 100$ najlepszy wynik osiągnęło krzyżowanie CX z mutacją Revert, dla $k = 100$ było to krzyżowanie CX z mutacją insert a pozostałych krzyżowanie CX z mutacją Swap. Globalnie najlepszy wynik został znaleziony dla $N = 2000$,

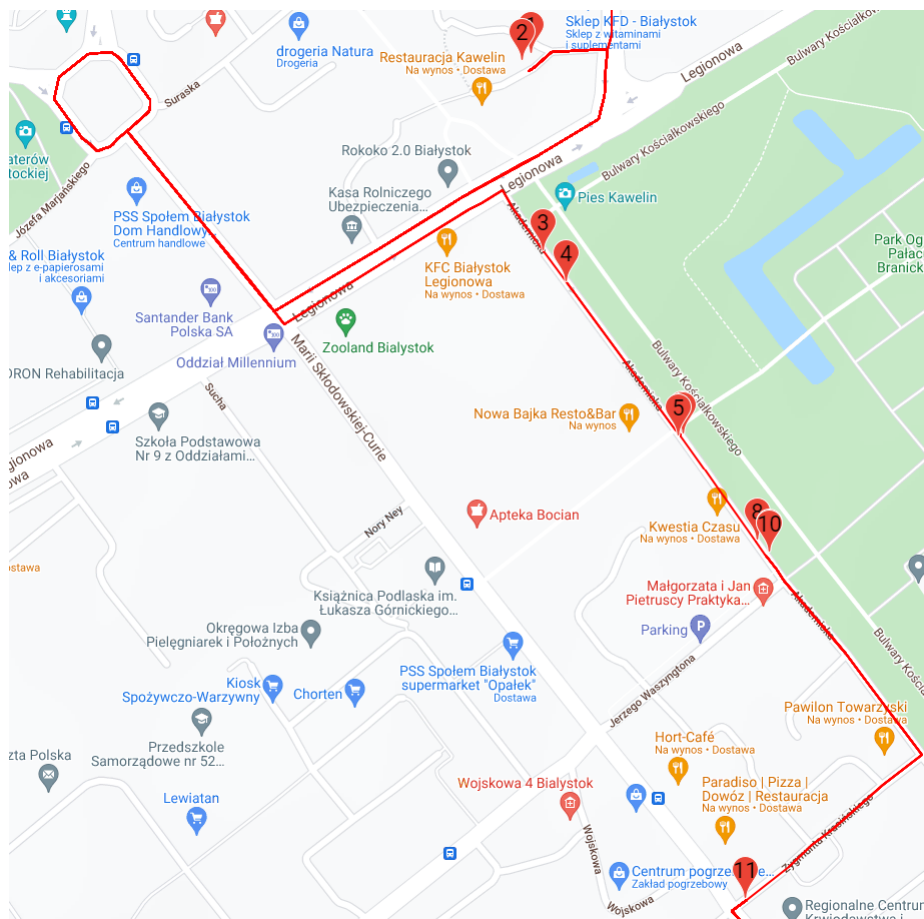


Rysunek 6.8: Fragment trasy algorytmu mrówkowego

$k = 2000$ i jest to 27381 metrów, lecz poprawa względem $N = 1000$ wyniosła tylko 500 metrów. Krzyżowanie PMX podobnie sobie poradziło jak krzyżowanie OX. Dla $N = 100$ w najlepszym przypadku udało się zoptymalizować trasę do 37172 metrów.

W tabeli 6.12 zostały pokazane średnie czasy trwania algorytmu genetycznego. Rozkład najlepszych średnich czasów jest bardzo podobny do trasy pierwszej. Najszybsze dla każdego N i k było krzyżowanie CX oraz mutacja Revert. Pomiedzy $N = 1000$ a $N = 2000$ średnia najlepsza optymalizacja trasy poprawiła się około 500 metrów, czas na znalezienie takiej trasy wzrósł ponad dwukrotnie z 4.17 sekund do 9.96 sekund. Najwolniej sobie poradziło krzyżowanie PMX. Od $k = 1000$ wraz ze wzrostem k czas wykonania rósł dwukrotnie.

Rysunki 6.10, 6.11 oraz 6.12 przedstawiają wykresy, które porównują o ile różni się rozwiązanie od długości trasy oryginalnej, kolejna dla $N=100$, $N=1000$ oraz $N = 2000$. Dla $N = 2000$ i $k = 1000$ dla krzyżowania CX oraz mutacji Insert algorytm zoptymalizował średnio trasę o 30.21 procent, przy wzroście liczby iteracji nie nastąpiła już poprawa. Algorytm cały



Rysunek 6.9: Fragment trasy algorytmu A*

czas optymalizował trasę około 30 procent. Dla $N = 1000$ trasa została zoptymalizowana maksymalnie około 25 procent zawsze dla krzyżowania CX oraz mutacji Swap lub Insert. Krzyżowanie PMX i OX zoptymalizowało trasę średni od około 15 do 20 procent. Przy $N = 100$ wyniki były gorsze niż oryginalna trasa o kilkadziesiąt procent, a przy $k = 100$ nawet osiągnęły -190 procent.

6.2.2 Wyniki algorytmu mrówkowego

Podobnie tak jak w przypadku trasy numer 1 algorytm został uruchomiony dziesięciokrotnie dla każdej możliwej wariacji parametrów wejściowych. Wynikiem jaki jest generowany przez algorytm są punkty w których znajdują się kontenery z odpadami, przebyty dystans, a także czas jaki trzeba było czekać na wygenerowanie wyniku. Tabele z wyliczonymi wynikami również zostały przedstawione według takiego samego schematu. Wiersze tabeli odpowiadają ilościom przeprowadzonych iteracji, a w kolumnach zawarte są informacje o współczynniku parowania.

Tabela 6.9: Trasa II - średnie wyniki algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 99575 | 107771 | 111797 | 113364 | 119707 | 120570 | 110318 | 116843 | 116749 |
| 100 | 1000 | 56105 | 70104 | 88449 | 60788 | 71531 | 93290 | 59452 | 70589 | 88734 |
| 100 | 2000 | 48407 | 61102 | 87698 | 50719 | 61516 | 92912 | 48634 | 61984 | 88546 |
| 100 | 4000 | 47154 | 54452 | 47154 | 48203 | 55866 | 92145 | 43488 | 52586 | 86276 |
| 1000 | 100 | 65248 | 67898 | 64703 | 78946 | 83318 | 81904 | 47854 | 46921 | 49695 |
| 1000 | 1000 | 39419 | 43935 | 55085 | 41294 | 46914 | 68463 | 30385 | 32616 | 43041 |
| 1000 | 2000 | 34882 | 40914 | 57467 | 39237 | 44605 | 65532 | 30631 | 31273 | 48346 |
| 1000 | 4000 | 36160 | 39848 | 55774 | 36414 | 44856 | 68215 | 30443 | 30720 | 48295 |
| 2000 | 100 | 58533 | 59876 | 60898 | 70291 | 71693 | 72095 | 38655 | 39129 | 37204 |
| 2000 | 1000 | 34939 | 38272 | 49381 | 35951 | 39779 | 62656 | 28196 | 29415 | 33519 |
| 2000 | 2000 | 32900 | 39068 | 48607 | 34474 | 41349 | 56907 | 28802 | 28506 | 34458 |
| 2000 | 4000 | 32626 | 36244 | 49132 | 36333 | 39164 | 57952 | 28808 | 28453 | 32683 |

Tabela 6.10: Trasa II - tbd algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 1000 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 2000 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 4000 | 10% | 0% | 10% | 0% | 0% | 0% | 30% | 0% | 0% |
| 1000 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 10% | 10% | 10% |
| 1000 | 1000 | 60% | 10% | 0% | 40% | 0% | 0% | 100% | 100% | 30% |
| 1000 | 2000 | 100% | 40% | 0% | 60% | 0% | 0% | 100% | 100% | 10% |
| 1000 | 4000 | 100% | 50% | 0% | 90% | 20% | 0% | 100% | 100% | 30% |
| 2000 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 90% | 70% | 70% |
| 2000 | 1000 | 90% | 60% | 0% | 100% | 50% | 0% | 100% | 100% | 100% |
| 2000 | 2000 | 100% | 70% | 10% | 100% | 40% | 0% | 100% | 100% | 80% |
| 2000 | 4000 | 100% | 90% | 20% | 100% | 70% | 0% | 100% | 100% | 100% |

Algorytm mrówkowy bardzo dobrze poradził sobie z optymalizacją trasy numer 2. W tabeli numer ?? przedstawione zostały najlepsze wyniki algorytmu mrówkowego dla tej trasy. Każdy z wyników jest lepszy od oryginalnej trasy. Prawie wszystkie wartości są niższe od 30 000 metrów. Dla drugiej trasy najkrótsza odległość jaką udało się uzyskać wynosi 24 347 metrów.


Najlepszy średni wynik wynosi 26 447. Jest to wynik który został uzyskany dla współczynnika parowania równego 0.2 i liczbie iteracji równej 50. Wyniki dla takiego samego współczynnika ale innej liczbie iteracji są na zbliżonym poziomie. Podobnie jak w przypadku poprzedniej trasy, najgorsza średnia została obliczona dla współczynnika parowania równego 0.1. Wraz ze wzrostem liczby iteracji następował progres. Ostatecznie dla 100 iteracji długość trasy jest zbliżona do najlepszych wyników. Ścieżka z największą średnią jest lepsza od oryginalnej i stanowi 78% jej długości.

Tabela 6.11: Trasa II - najlepsze wyniki algorytmu genetycznego dla danych parametrów wejściowych

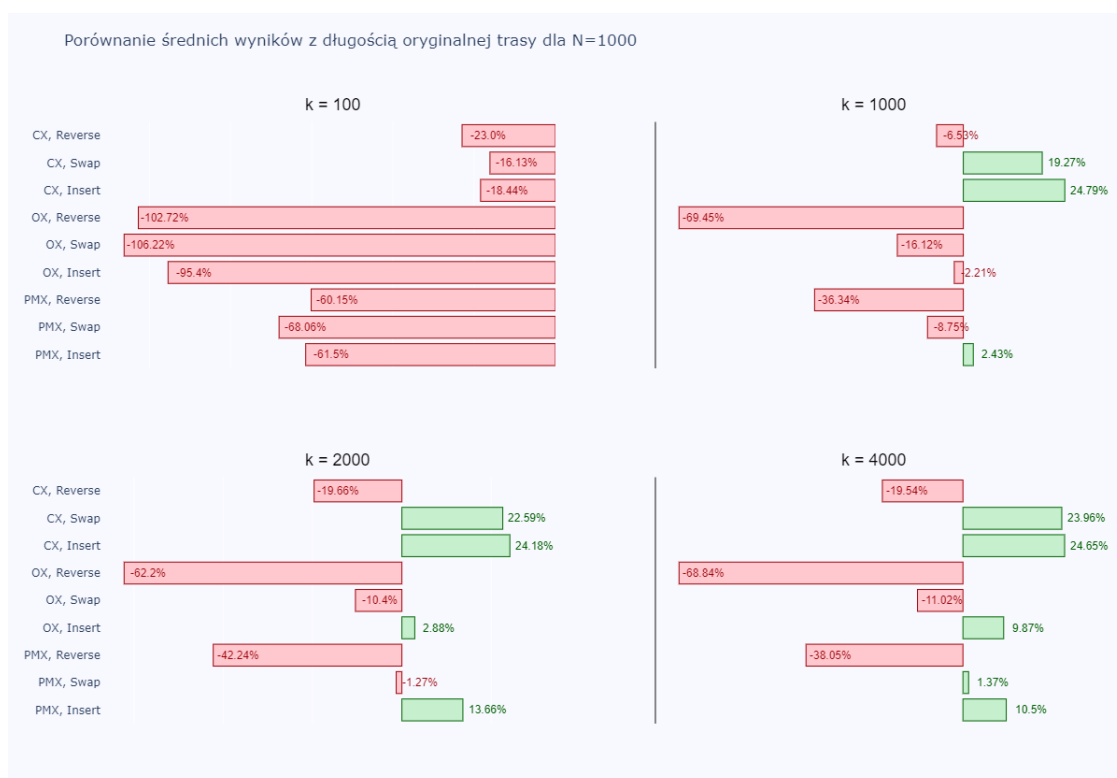
| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 89707 | 95824 | 100856 | 102788 | 110057 | 114491 | 104749 | 104765 | 101883 |
| 100 | 1000 | 44863 | 63868 | 76641 | 54433 | 59588 | 80783 | 53688 | 55723 | 75815 |
| 100 | 2000 | 42084 | 56000 | 79817 | 46908 | 54427 | 86609 | 43440 | 48834 | 80426 |
| 100 | 4000 | 40309 | 49246 | 40309 | 43816 | 49864 | 78281 | 37172 | 47158 | 78780 |
| 1000 | 100 | 53565 | 59523 | 59419 | 71181 | 75567 | 73827 | 40068 | 38220 | 33442 |
| 1000 | 1000 | 34352 | 38069 | 48381 | 34282 | 44087 | 62194 | 28947 | 29655 | 34089 |
| 1000 | 2000 | 32942 | 36491 | 48353 | 33013 | 40481 | 58856 | 28047 | 27858 | 35650 |
| 1000 | 4000 | 33021 | 33720 | 47438 | 29602 | 38640 | 57355 | 28442 | 28027 | 35271 |
| 2000 | 100 | 50007 | 53464 | 51193 | 61228 | 67171 | 59619 | 33775 | 35063 | 31852 |
| 2000 | 1000 | 29758 | 33420 | 43562 | 32178 | 33255 | 56070 | 27655 | 27910 | 29839 |
| 2000 | 2000 | 31390 | 35329 | 38151 | 30047 | 31229 | 48944 | 28178 | 27381 | 29839 |
| 2000 | 4000 | 30080 | 31724 | 38944 | 32360 | 35025 | 49517 | 28177 | 27925 | 29840 |

Tabela 6.12: Trasa II - średnie czasy wykonywania algorytmu dla danych parametrów wejściowych


| N | k | PMX Insert | PMX Replace | PMX Revert | OX Insert | OX Replace | OX Revert | CX Insert | CX Replace | CX Revert |
|------|------|---------------|----------------|---------------|--------------|---------------|--------------|--------------|---------------|--------------|
| 100 | 100 | 0,04 | 0,04 | 0,03 | 0,02 | 0,02 | 0,02 | 0,03 | 0,02 | 0,02 |
| 100 | 1000 | 0,27 | 0,26 | 0,24 | 0,20 | 0,19 | 0,18 | 0,24 | 0,16 | 0,15 |
| 100 | 2000 | 0,50 | 0,49 | 0,46 | 0,38 | 0,37 | 0,35 | 0,41 | 0,31 | 0,29 |
| 100 | 4000 | 0,95 | 0,95 | 0,95 | 0,75 | 0,72 | 0,69 | 0,74 | 0,60 | 0,59 |
| 1000 | 100 | 0,54 | 0,53 | 0,53 | 0,34 | 0,33 | 0,32 | 0,39 | 0,29 | 0,28 |
| 1000 | 1000 | 3,24 | 3,13 | 2,99 | 2,49 | 2,40 | 2,28 | 2,26 | 1,95 | 1,91 |
| 1000 | 2000 | 5,95 | 5,89 | 5,79 | 4,57 | 4,33 | 4,33 | 4,17 | 3,90 | 3,65 |
| 1000 | 4000 | 11,81 | 11,91 | 11,30 | 8,96 | 9,23 | 8,64 | 8,10 | 7,34 | 7,26 |
| 2000 | 100 | 1,17 | 1,19 | 1,12 | 0,76 | 0,75 | 0,74 | 0,84 | 0,66 | 0,64 |
| 2000 | 1000 | 7,17 | 7,55 | 6,98 | 5,56 | 5,51 | 5,23 | 5,11 | 4,56 | 4,45 |
| 2000 | 2000 | 13,61 | 13,61 | 13,48 | 10,71 | 11,13 | 10,64 | 9,96 | 9,03 | 8,93 |
| 2000 | 4000 | 27,25 | 27,60 | 27,11 | 21,06 | 21,97 | 21,21 | 18,63 | 17,79 | 17,43 |



Rysunek 6.10: Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=100



Rysunek 6.11: Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=1000



Rysunek 6.12: Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=2000

Tabela 6.13: Trasa II - najlepsze wyniki algorytmu mrówkowego dla danych parametrów wejściowych


| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 31995 | 25023 | 25209 | 25119 | 26103 | 25560 | 25799 | 28107 | 26360 |
| 75 | 26037 | 25686 | 25330 | 24347 | 26291 | 25999 | 25912 | 27805 | 25776 |
| 100 | 25820 | 25343 | 24760 | 24404 | 26080 | 25136 | 25695 | 27485 | 26650 |

Tabela 6.14: Trasa II - średnie wyniki algorytmu mrówkowego dla danych parametrów wejściowych

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 35518 | 26447 | 27146 | 26449 | 28817 | 28061 | 28672 | 30477 | 29670 |
| 75 | 26937 | 26812 | 27660 | 26896 | 28351 | 28242 | 29070 | 29968 | 28910 |
| 100 | 26721 | 26532 | 26888 | 27358 | 28191 | 28116 | 29397 | 29738 | 28608 |

Dla najmniejszej ilości iteracji, zostają wygenerowane trasy krótsze od pierwotnej. Na wykresie 6.13 zostały przedstawione średnie wyniki dla 50 iteracji. Można na tym wykresie zauważyć, że najdłuższe trasy były generowane dla najniższego współczynnika parowania. Najkrótsze trasy były generowane w przedziale od 0.2 do 0.4. Dla pozostałych współczynników wartości są większe od 24%.

Porównanie średnich wyników z długością oryginalnej trasy.




Rysunek 6.13: Procentowy rozkład średnich wartości dla 50 iteracji

Po zwiększeniu liczby iteracji do 75, na wykresie 6.15 można zauważyć zmiany w średnich dystansach ścieżek. Na szczególną uwagę zasługują współczynniki o wartości 0.1. Jeśli liczba iteracji była zmniejszona o 25, to średnie wyniki były najgorsze. Po zwiększeniu iteracji o 25, sytuacja odwróciła się o 180 stopni. Średnia z tras dla współczynnika parowania feromonów równego 0.1 była jedną z najlepszych w całym zestawieniu. Pozostałe wyniki są co najmniej 25% lepsze od oryginalnego przebytego dystansu.

Maksymalna liczba iteracji w niewielkim stopniu polepszyła wcześniejsze wyniki. Ponownie najkrótsze trasy zostały wygenerowane dla współczynników parowania z dolnego zakresu. Nie zmienia to faktu, iż wszystkie wyniki w dalszym ciągu były lepsze od badanej oryginalnej trasy.

Dzięki tabeli ?? można zauważyć jakie optymalizacje wykonał algorytm mrówkowy. Wartością każdej komórki tabeli jest 100%. Świadczy to o tym, że każda z tras jaka została

Porównanie średnich wyników z długością oryginalnej trasy.



Rysunek 6.14: Procentowy rozkład średnich wartości dla 75 iteracji


wygenerowana przez algorytm mrówkowy jest lepsza od oryginalnej. W tej sytuacji bez znaczenia jest liczba iteracji czy też współczynnik parowania.

Tabela 6.15: Trasa II - suma lepszych tras w porównaniu do oryginalnej

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|------|------|------|------|------|------|------|------|------|
| 50 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |
| 75 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |
| 100 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |

Oprócz krótszych tras uwagę należy zwrócić na czas jaki program potrzebował na ich optymalizację. Średni czas oczekiwania dla najmniejszej wartości iteracji wynosił 28.325 sekund. Pomiar czasu trwania algorytmu przy 75 iteracjach trwał 42.689. Najdłużej program wykonywał się dla 100 iteracji. Czas ten został oszacowany na 60.281.

Porównanie średnich wyników z długością oryginalnej trasy.



Rysunek 6.15: Procentowy rozkład średnich wartości dla 100 iteracji

Tabela 6.16: Trasa II - średnie wyniki czasu wykonania algorytmu mrówkowego dla parametru ilości iteracji

| | | | |
|----------|--------|--------|--------|
| iteracje | 50 | 75 | 100 |
| czas | 28.325 | 42.689 | 60.281 |

6.2.3 Wyniki algorytmów zachłannych

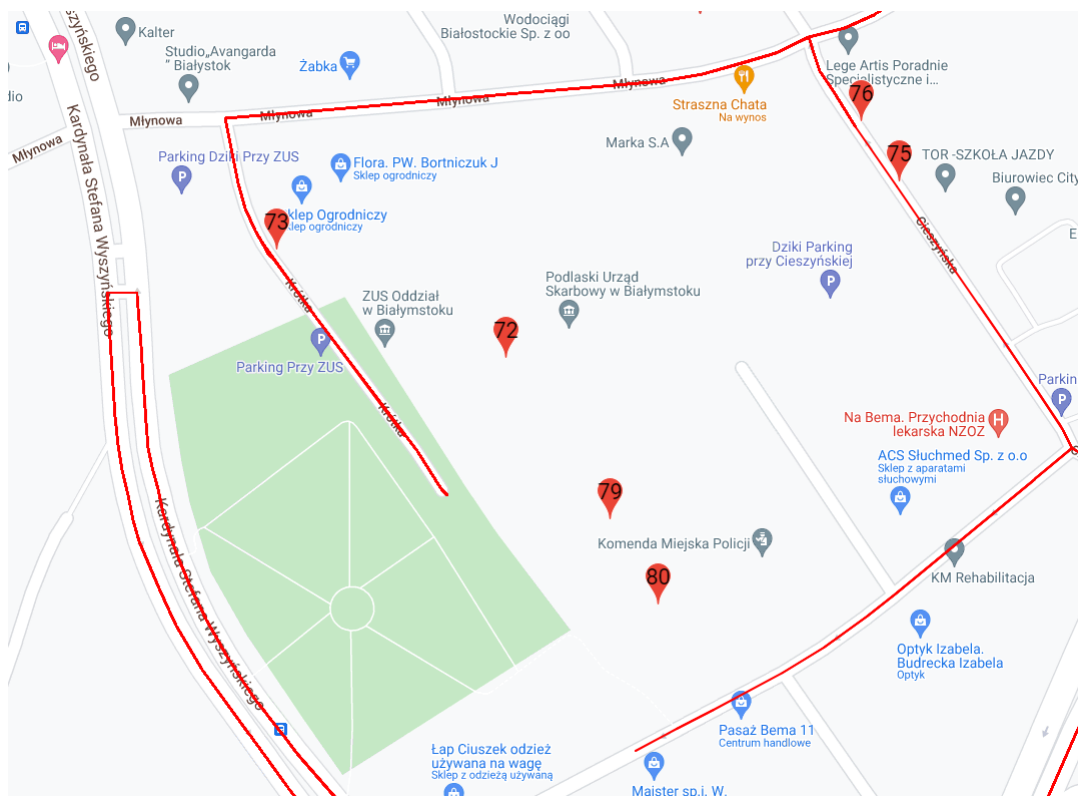
6.2.4 Porównanie algorytmów

Podobnie jak w przypadku trasy numer 1, najlepsze wyniki algorytmów nie są takie same. Ponownie przeprowadzone optymalizacje przyniosły spodziewany efekt. Najlepszym wynikiem algorytmu genetycznego jest 27 381. W stosunku do oryginalnej trasy jest to poprawa o 40%. Czas z jakim pracował program aby wygenerować taki wynik to 9.03 sekund. Ponownie najlepszy wynik został osiągnięty przez algorytm mrówkowy.


Łączy przebyty dystans dla tego rozwiązania to 24 347. Jest to o 46% wynik lepszy od pierwotnej trasy. Czas oczekiwania na ten rezultat wynosił 28.32 sekund. Natomiast algorytmy zachłanne, a dokładnie algorytm A*, znalazły trasę o długości 32 855 metrów, a przy zastosowaniu metody 2-opt wynik ten uległ poprawie do 28 757 metrów. Do wykonania wszystkich operacji potrzebne było 20.59 sekundy.

Najgorszy wynik został wygenerowany przez algorytm A*. Czas działania tego algorytmu również nie wyróżnia się spośród pozostałych rozwiązań. Lepszym wynik został wygenerowany przy użyciu algorytmu genetycznego. Wynik ten został osiągnięty w najkrótszym czasie spośród wszystkich trzech rozwiązań. Najlepszy wynik ponownie został wygenerowany przez algorytm mrówkowy. Czas wykonania programu również i w tym przypadku był najdłuższy.

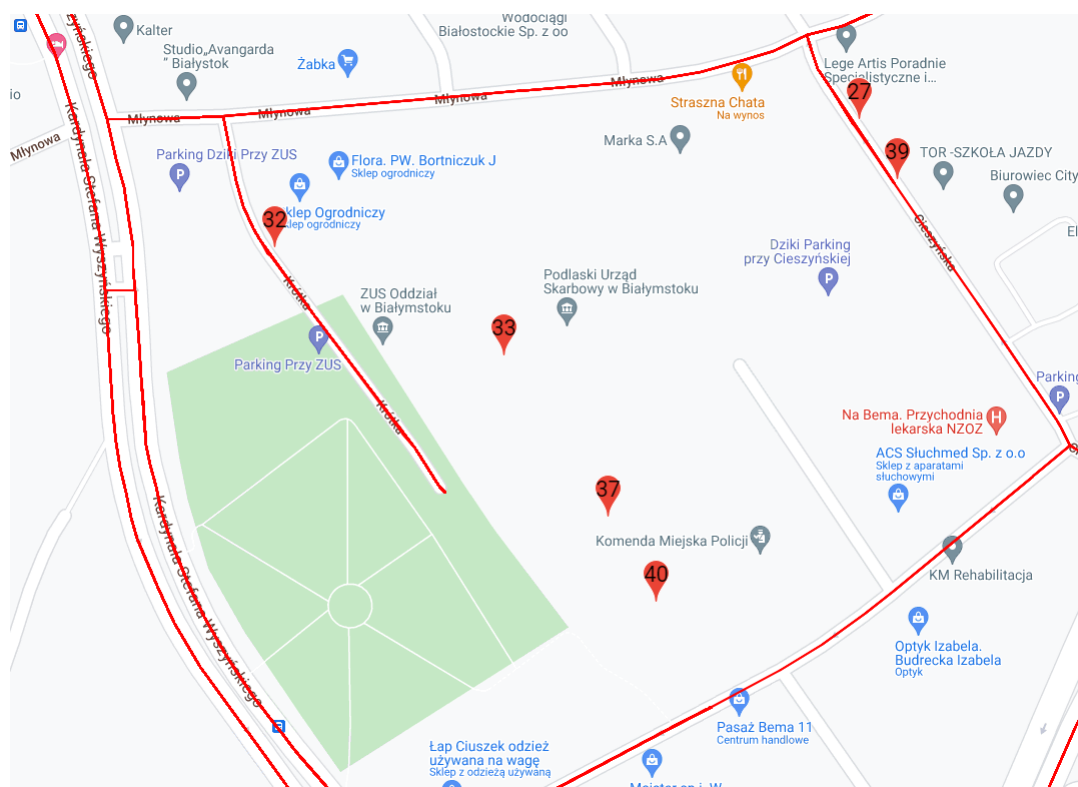
Na zdjęciach 6.16, 6.17, 6.18 zostały pokazane przykładowe różnice w wygenerowanych trasach przez algorytmy. Na przedstawionych fragmentach można zauważyć, że punkty były odwiedzane w różnych kolejnościach. Dodatkowo na uwagę zasługuje fakt, iż w każdym z rozwiązań pojazd w inny sposób pokonał ulicę Wyszyńskiego.



Rysunek 6.16: Fragment trasy algorytmu genetycznego



Rysunek 6.17: Fragment trasy algorytmu mrówkowego



Rysunek 6.18: Fragment trasy algorytmu A*

6.3 Trasa III

Trasa trzecia składa się z 248 punktów i ma długość 53478 metrów.

6.3.1 Wyniki algorytmu genetycznego

W tabeli 6.17 zostały pokazane średnie wyniki algorytmu genetycznego dla trasy III. Krzyżowanie OX ani razu nie osiągnęło średniego wyniku lepszego od długości trasy oryginalnej. Dla $N = 100$, większość otrzymanych wyników ma wartość powyżej 100 kilometrów. Dopiero dla $N = 1000$, $k = 1000$, krzyżowania CX oraz mutacji Insert udało się osiągnąć średni lepszy wynik od wartości oryginalnej 423728 metrów, jest to poprawa długości około 10 kilometrów. Najlepszy wynik dla $N = 1000$ wystąpił dla $k = 4000$, krzyżowania CX oraz mutacji Insert, wyniósł 40121 metrów. Dla tej populacji krzyżowanie PMX w jednym miejscu osiągnęło średni wynik lepszy niż długość trasy oryginalnej, dla $k = 4000$ oraz mutacji Insert. Dla populacji $N = 2000$ wyniki rozłożyły się podobnie do poprzedniej. Najlepszy globalny wynik 34168 metrów został osiągnięty dla krzyżowania CX, mutacji Insert o $k = 4000$.

Tabela 6.17: Trasa III - Średnie wyniki algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 202200 | 215800 | 223134 | 226673 | 238350 | 244471 | 226996 | 238909 | 248130 |
| 100 | 1000 | 101445 | 119726 | 156991 | 108762 | 130635 | 168963 | 121076 | 140420 | 170028 |
| 100 | 2000 | 88501 | 112378 | 149298 | 95249 | 112897 | 159348 | 95405 | 110801 | 162912 |
| 100 | 4000 | 81056 | 97882 | 151635 | 80120 | 99671 | 163374 | 74624 | 97972 | 153400 |
| 1000 | 100 | 138988 | 141411 | 138102 | 159437 | 165202 | 161127 | 100709 | 114035 | 108668 |
| 1000 | 1000 | 60548 | 66745 | 93017 | 70666 | 76984 | 117566 | 43728 | 54573 | 85516 |
| 1000 | 2000 | 53736 | 68402 | 96311 | 59332 | 71183 | 117932 | 42545 | 50305 | 90144 |
| 1000 | 4000 | 49323 | 66474 | 96935 | 56877 | 69448 | 118314 | 40121 | 48213 | 86232 |
| 2000 | 100 | 126626 | 127066 | 125408 | 147299 | 148430 | 147276 | 64776 | 89803 | 81523 |
| 2000 | 1000 | 54123 | 64199 | 82598 | 57743 | 68314 | 103521 | 34365 | 39530 | 50624 |
| 2000 | 2000 | 45893 | 55922 | 82523 | 54700 | 63697 | 96266 | 36518 | 39200 | 59014 |
| 2000 | 4000 | 47206 | 57436 | 81653 | 54149 | 66321 | 96440 | 34168 | 37951 | 56645 |

W tabeli 6.18 została przedstawiona procentowa ilość wyników lepszych od długości trasy oryginalnej. Dla $N = 100$, $N = 1000$ i $k = 100$ oraz $N = 2000$ i $k = 100$ nie wystąpił ani jeden wynik, który optymalizowałby trasę. Krzyżowanie PMX osiągnęło tylko raz skuteczność 100 procent dla $N = 2000$, $k = 2000$ oraz mutacji Insert. Mutacja Revert ani razu dla krzyżowania PMX oraz OX nie zoptymalizowała wyniku. Dopiero dla krzyżowania CX i $N = 2000$ algorytm genetyczny miał skuteczność na poziomie 40 - 60 procent. Krzyżowanie CX z mutacją Insert uzyskało dla pięciu różnych kombinacji wartości N i k 100 procent skuteczności.

Tabela 6.18: Trasa III - tbd algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX | PMX | PMX | OX | OX | OX | CX | CX | CX |
|------|------|--------|---------|--------|--------|---------|--------|--------|---------|--------|
| | | Insert | Replace | Revert | Insert | Replace | Revert | Insert | Replace | Revert |
| 100 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 1000 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 2000 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 100 | 4000 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 1000 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 1000 | 1000 | 0% | 0% | 0% | 0% | 0% | 0% | 100% | 40% | 0% |
| 1000 | 2000 | 50% | 0% | 0% | 10% | 0% | 0% | 90% | 70% | 0% |
| 1000 | 4000 | 90% | 0% | 0% | 30% | 0% | 0% | 100% | 70% | 0% |
| 2000 | 100 | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% | 0% |
| 2000 | 1000 | 40% | 10% | 0% | 10% | 0% | 0% | 100% | 100% | 60% |
| 2000 | 2000 | 100% | 30% | 0% | 80% | 10% | 0% | 100% | 100% | 40% |
| 2000 | 4000 | 90% | 30% | 0% | 50% | 0% | 0% | 100% | 100% | 30% |

Tabela 6.19: Trasa III - najlepsze wyniki algorytmu genetycznego dla danych parametrów wejściowych

| N | k | PMX | PMX | PMX | OX | OX | OX | CX | CX | CX |
|------|------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| | | Insert | Swap | Revert | Insert | Swap | Revert | Insert | Swap | Revert |
| 100 | 100 | 178235 | 179169 | 210255 | 214392 | 220255 | 225128 | 199164 | 209900 | 228851 |
| 100 | 1000 | 92035 | 97541 | 145836 | 92447 | 119218 | 156940 | 108633 | 134528 | 147851 |
| 100 | 2000 | 75472 | 99019 | 133028 | 82103 | 100138 | 150643 | 82086 | 100030 | 146323 |
| 100 | 4000 | 66386 | 84653 | 128228 | 67843 | 87629 | 150569 | 64530 | 85814 | 128407 |
| 1000 | 100 | 130408 | 129829 | 113771 | 146677 | 146199 | 146851 | 80069 | 80657 | 91467 |
| 1000 | 1000 | 54442 | 57812 | 79987 | 65279 | 70631 | 98505 | 37536 | 44330 | 70152 |
| 1000 | 2000 | 43708 | 57296 | 67415 | 51213 | 57795 | 97761 | 36381 | 39559 | 64270 |
| 1000 | 4000 | 43938 | 57678 | 81284 | 47695 | 60624 | 102346 | 34365 | 38618 | 69499 |
| 2000 | 100 | 117579 | 114351 | 112117 | 133323 | 133203 | 140060 | 58239 | 66450 | 64827 |
| 2000 | 1000 | 46490 | 47507 | 72252 | 50359 | 60606 | 91474 | 32374 | 33408 | 41138 |
| 2000 | 2000 | 42326 | 44568 | 70413 | 45282 | 53114 | 81577 | 33070 | 36492 | 41724 |
| 2000 | 4000 | 43332 | 49969 | 69794 | 46970 | 56971 | 83286 | 32478 | 33962 | 41975 |

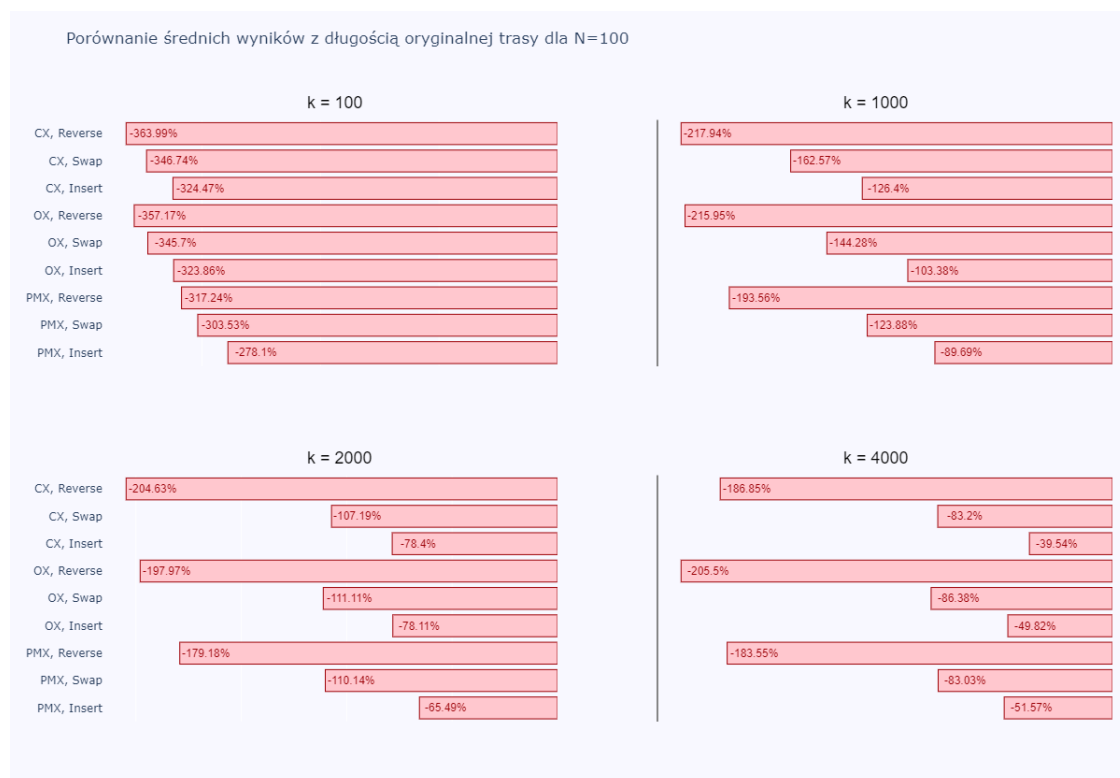
W tabeli 6.19 przedstawiono najlepsze wyniki algorytmu genetycznego dla poszczególnych parametrów wejściowych. Algorytm genetyczny znalazł wyniki lepsze od długości trasy oryginalnej od $N = 1000$ i $k = 1000$. Najlepszy osiągnięty wynik dla $N = 1000$ to 34365 metrów, czyli optymalizacja o prawie 20 kilometrów. Algorytm genetyczny z krzyżowaniem PMX dla tej populacji osiągnęło najlepszy wynik 43708 metrów. Najlepszy globalny wynik został osiągnięty dla $N = 2000$, $k = 1000$, krzyżowania CX oraz mutacji Insert wyniósł 32372 metrów. Krzyżowanie PMX poprawiło się nieznacznie.

6.3.2 Wyniki algorytmu mrówkowego

Na ostatniej badanej trasie, wyniki algorytmu mrówkowego również wyglądają dobrze. Analizując tabelę ?? łatwo zauważyć, że wszystkie średnie wyniki były lepsze od pierwotnej długości. W najgorszym przypadku średni wynik ma wartość 39 797 metrów.

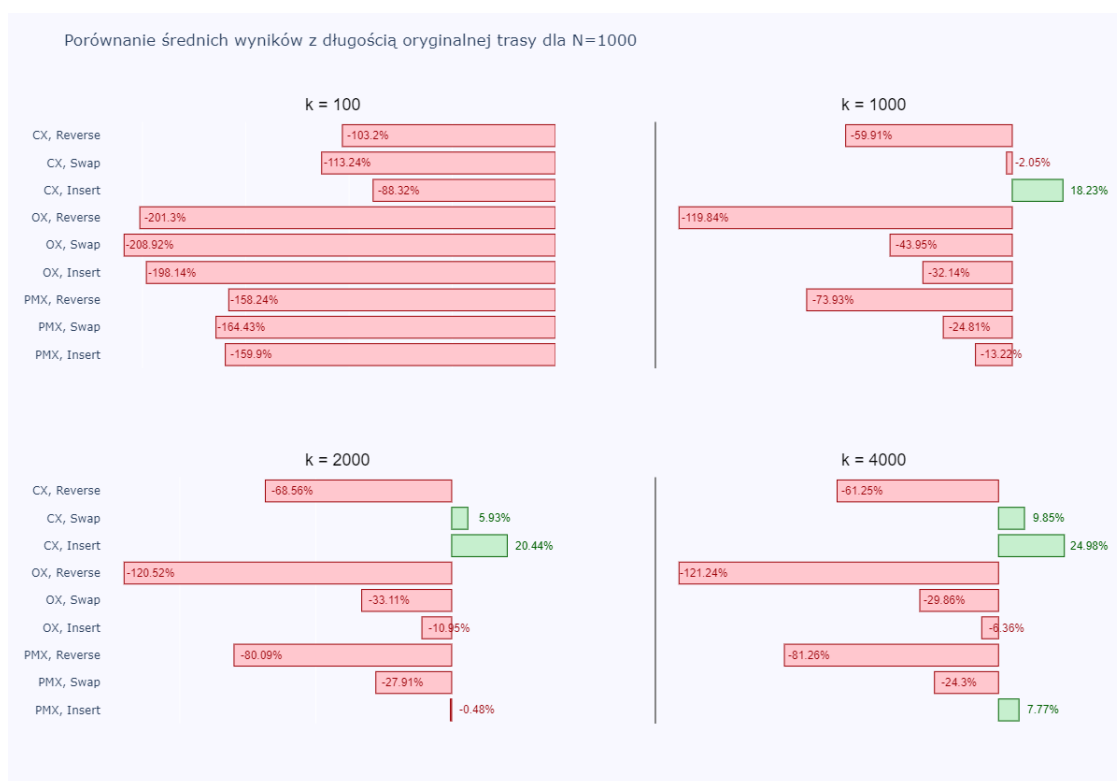
Tabela 6.20: Trasa III - średnie czasy wykonywania algorytmu dla danych parametrów wejściowych

| N | k | PMX Insert | PMX Swap | PMX Revert | OX Insert | OX Swap | OX Revert | CX Insert | CX Swap | CX Revert |
|------|------|---------------|-------------|---------------|--------------|------------|--------------|--------------|------------|--------------|
| 100 | 100 | 0,09 | 0,07 | 0,06 | 0,04 | 0,04 | 0,03 | 0,07 | 0,03 | 0,03 |
| 100 | 1000 | 0,44 | 0,43 | 0,35 | 0,32 | 0,31 | 0,26 | 0,48 | 0,25 | 0,22 |
| 100 | 2000 | 0,83 | 0,79 | 0,69 | 0,60 | 0,58 | 0,52 | 0,78 | 0,46 | 0,44 |
| 100 | 4000 | 1,51 | 1,48 | 1,35 | 1,12 | 1,11 | 1,03 | 1,28 | 0,89 | 0,84 |
| 1000 | 100 | 1,06 | 1,06 | 1,06 | 0,61 | 0,60 | 0,57 | 0,76 | 0,52 | 0,52 |
| 1000 | 1000 | 5,47 | 5,40 | 4,64 | 3,85 | 3,81 | 3,30 | 3,85 | 2,87 | 2,79 |
| 1000 | 2000 | 9,48 | 9,29 | 8,36 | 6,98 | 6,95 | 6,23 | 7,12 | 5,52 | 5,49 |
| 1000 | 4000 | 17,64 | 17,06 | 15,82 | 13,01 | 13,03 | 12,11 | 12,22 | 10,65 | 10,56 |
| 2000 | 100 | 2,61 | 2,53 | 2,46 | 1,49 | 1,52 | 1,44 | 1,89 | 1,30 | 1,32 |
| 2000 | 1000 | 13,40 | 13,30 | 11,46 | 9,34 | 9,24 | 7,90 | 8,25 | 7,07 | 6,93 |
| 2000 | 2000 | 21,82 | 21,51 | 20,35 | 16,03 | 16,04 | 14,76 | 14,59 | 13,04 | 12,60 |
| 2000 | 4000 | 38,35 | 38,67 | 37,01 | 30,41 | 30,20 | 28,53 | 26,81 | 25,30 | 24,47 |




Rysunek 6.19: Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=100

Jest to wynik o 26% lepszy od oryginalnej trasy. Taki wynik został wygenerowany przy najniższej liczbie iteracji oraz dla współczynnika parowania wynoszącego 0.1. Dla tego samego współczynnika wraz ze wzrostem iteracji wynik ulega polepszeniu. Najlepszy wynik dla tego współczynnika wynosi 31 935 metrów. Różnica między tą wartością a najlepszą wartością dla całej trasy jest nieduża i wynosi 359 metrów. Wartość 31 576 metrów jest o 41% lepszym wynikiem od trasy oryginalnej.



Rysunek 6.20: Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=1000



Rysunek 6.21: Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=2000

Tabela 6.21: Trasa III - średnie wyniki algorytmu mrówkowego dla danych parametrów wejściowych

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 39797 | 31576 | 33115 | 34142 | 35197 | 35392 | 34947 | 35023 | 35678 |
| 75 | 32302 | 32777 | 34365 | 33947 | 34407 | 35280 | 35765 | 34893 | 36052 |
| 100 | 31935 | 32737 | 33768 | 33181 | 34423 | 34415 | 35571 | 36381 | 35566 |

Do wygenerowania najkrótszej trasy potrzeba było 75 iteracji. Współczynnik parowania dla tej trasy wynosi 0.1. Można zauważyć, jak ilość iteracji potrafi wpłynąć na wynik. Dla najniższej ilości iteracji wygenerowana trasa jest dużo dłuższa od pozostałych dwóch wariantów. Dla większości współczynników parowania sytuacja jest podobna. Wraz ze wzrostem liczby iteracji wyniki są lepsze. Dla wartości z zakresu od 0.6 do 0.9 trend ten jest zmieniony. Przykładowo dla współczynnika parowania równego 0.8, program utworzył najlepszą trasę przy 75 iteracjach. Najdłuższa trasa została natomiast odnotowana dla największej liczby iteracji.

Tabela 6.22: Trasa III - najlepsze wyniki algorytmu mrówkowego dla danych parametrów wejściowych


| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 50 | 38271 | 29339 | 30505 | 31383 | 31255 | 31141 | 30948 | 31304 | 32184 |
| 75 | 28172 | 28860 | 31254 | 30693 | 30415 | 32098 | 31372 | 29923 | 31230 |
| 100 | 28311 | 29084 | 31542 | 30573 | 30254 | 30428 | 29279 | 33067 | 30334 |

Poza analizą najlepszych tras, na uwagę zasługuje porównanie oryginalnej trasy ze średnicą wyniki dla każdego ze współczynników. Na wykresie 6.22 można zauważyć, że dla najniższej badanej liczby iteracji średnia wszystkich wyników była większa o minimum 25%. Największą średnią uzyskaną podczas badań odnotowana dla współczynnika parowania równego 0.2. Średnia ta była większa o 40.96%.

Na wykresie 6.23 zostały przedstawione średnie wyniki dla 75 iteracji. Wszystkie wartości są lepsze od początkowych. Najlepsza wartość została odnotowana dla współczynnika parowania wynoszącego 0.1. Jest to największy progres względem mniejszej liczby iteracji.

Po zwiększeniu liczby iteracji wartości nadal utrzymywały się na wysokim poziomie. Wszystkie średnie były większe od pierwotnej trasy. Żadna średnia nie była mniejsza od 30%. Tak jak dla 75 iteracji, tak i dla 100, najlepsze średnie wyniki zostały odnotowane dla współczynnika wartości równego 0.1.


Porównanie średnich wyników z długością oryginalnej trasy.



Rysunek 6.22: Wykres 1

Skuteczność z jaką algorytm mrówkowy zoptymalizował trasę jest najwyższa z możliwych. W tabeli ?? została przedstawiona procentowa wartość tras zoptymalizowanych w stosunku do oryginalnej odległości. Wszystkie z prób okazały się lepsze. Dzięki temu można zauważyć, że niezależnie od ilości iteracji wygenerowany wynik da satysfakcjonujący wynik. Ma to znaczenie w kontekście czasu jaki potrzebuje program na ulepszenie trasy. Tak jak w przypadku poprzednich tras, algorytm mrówkowy potrzebuje wykonać wiele operacji. Do wykonania 50 prób polepszenia trasy potrzeba średnio 84.451 sekundy. Jeśli ilość prób została zwiększona do 75, to średni czas wzrósł do 131.146 sekund. Najdłużej trwało obliczanie trasy dla 100 iteracji. Czas ten wyniósł 176.874 sekund.

Porównanie średnich wyników z długością oryginalnej trasy.



Rysunek 6.23: Wykres 1


Tabela 6.23: Trasa III - suma lepszych tras w porównaniu do oryginalnej

| k | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 |
|-----|------|------|------|------|------|------|------|------|------|
| 50 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |
| 75 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |
| 100 | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% | 100% |

Tabela 6.24: Trasa III - średnie wyniki czasu wykonania algorytmu mrówkowego dla parametru ilości iteracji

| iteracje | 50 | 75 | 100 |
|----------|--------|---------|---------|
| czas | 84.451 | 131.146 | 176.874 |

Porównanie średnich wyników z długością oryginalnej trasy.



Rysunek 6.24: Wykres 1

6.3.3 Wyniki algorytmów zachłannych

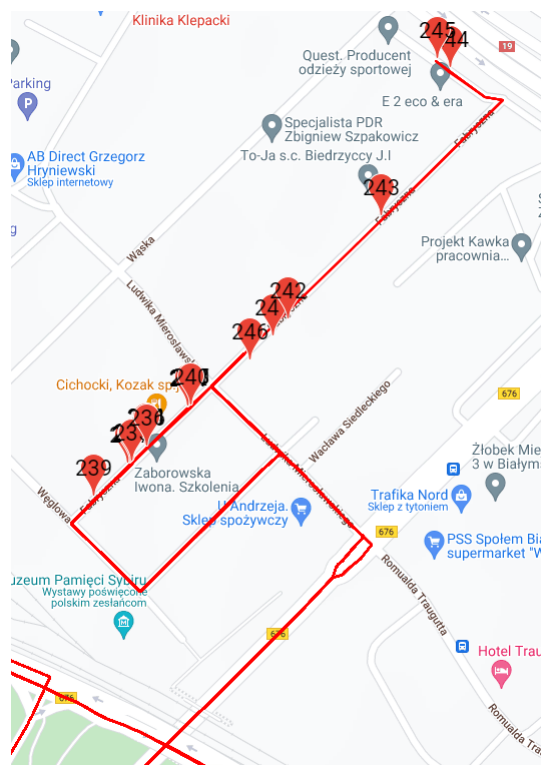
6.3.4 Porównanie algorytmów

Ostatnia z tras składała się z największej liczby punktów. Wszystkie algorytmy wykonywały się dłużej niż na poprzednich trasach. Każdy z algorytmów poprawił pierwotną trasę. Algorytm genetyczny wygenerował trasę o długości 32 374. W porównaniu do oryginału jest to poprawa o 40%. Program potrzebował średnio 8.25 sekundy na optymalizację trasy. Najlepszy rezultat został otrzymany przy pomocy algorytmu mrówkowego. Trasa o długości 28 172 jest krótsza o 47% od początkowej ścieżki. Średni czas z jakim pracował algorytm nad wygenerowaniem takiej trasy to 131.146 sekundy. Najkrótsza ścieżka dla algorytmów zachłannych została znaleziona przez algorytm A* o długości 32 855 metrów z czasem działania algorytmu 7.66 sekund. Po zoptymalizowaniu otrzymanych tras metodą 2-opt


otrzymano algorytmem najbliższego sąsiada lepszy wynik o wartości 31 781 w czasie 65.1 sekundy. Jest to wartość o 41% lepsza od oryginalnej.

Najdłuższa trasa została wygenerowana przy użyciu algorytmu genetycznego. Jednak czas jaki był potrzebny na tą optymalizację był o wiele krótszy od pozostałych dwóch algorytmów. Algorytm najbliższego sąsiada jest niewiele lepszy od algorytmu genetycznego. Czas potrzebny na wszystkie operacje był ponad siedmiokrotnie dłuższy. Najkrótsza trasa została wygenerowana przez algorytm mrówkowy. Niestety czas potrzebny do wygenerowania trasy był najdłuższy.

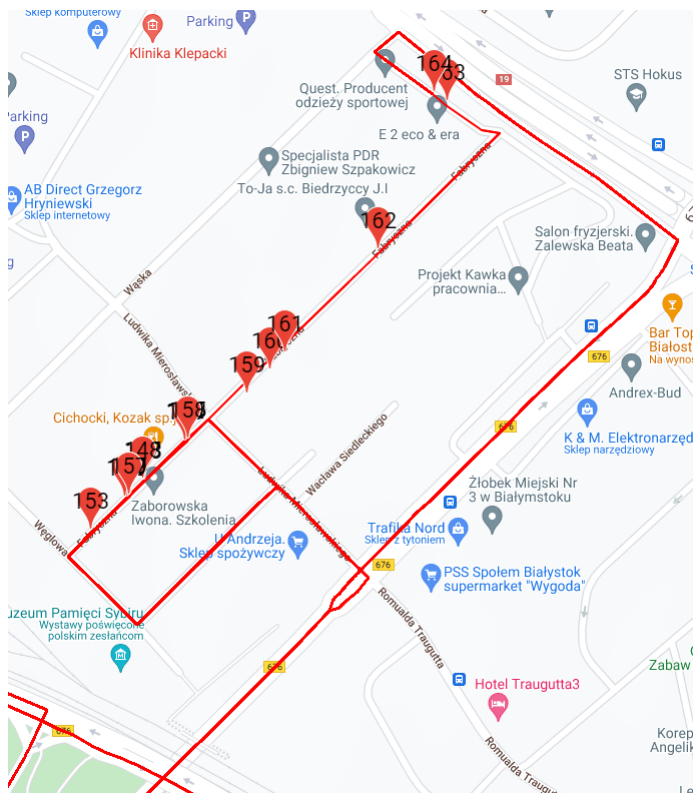
Na zdjęciach 6.16, 6.17, 6.18 zostały pokazane przykładowe różnice w znalezionych trasach na tym samym odcinku przez algorytmy. Każdy z algorytmów w innej kolejności odwiedził te punkty. Algorytm mrówkowy już na samym początku wyselekcjonował widoczne punkty. Natomiast algorytm genetyczny na samym końcu przeanalizował przedstawiony obszar. Jeszcze inaczej zachował się algorytm najbliższego sąsiada, który w środku trasy odwiedził punkty.



Rysunek 6.25: Fragment trasy algorytmu genetycznego



Rysunek 6.26: Fragment trasy algorytmu mrówkowego



Rysunek 6.27: Fragment trasy algorytmu najbliższego sąsiada

7. Rysunki Przemek

7.1 Trasa 1

Tabela 7.1: Trasa I - wyniki algorytmów zachłannych

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 37224 | 31895 | 38707 | 42343 | 32480 | 38497 | 31235 | 30906 | 36361 |
| 5 | 37224 | 32552 | 37925 | 42343 | 32479 | 39651 | 30906 | 30855 | 37143 |
| 10 | 37224 | 32552 | 38270 | 42335 | 32479 | 38496 | 30577 | 30855 | 36752 |
| 20 | 36840 | 32223 | 37879 | 40319 | 32479 | 38496 | 30577 | 30855 | 37143 |
| 30 | 36840 | 31895 | 38270 | 42335 | 33453 | 40421 | 31235 | 30205 | 36361 |
| 40 | 36840 | 32552 | 38270 | 42335 | 32479 | 38496 | 30577 | 30529 | 36317 |
| 50 | 37218 | 32552 | 37879 | 42335 | 32479 | 39651 | 30577 | 30854 | 36708 |
| 75 | 36842 | 32552 | 38660 | 40319 | 34103 | 38496 | 30899 | 30205 | 37098 |
| 100 | 36466 | 31895 | 38124 | 40319 | 32015 | 40421 | 31228 | 30205 | 37098 |

Tabela 7.2: Trasa I - optymalizacja wyników względem oryginalnej trasy

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 18.90% | 30.51% | 15.67% | 7.74% | 29.23% | 16.12% | 31.95% | 32.66% | 20.78% |
| 5 | 18.90% | 29.08% | 17.37% | 7.74% | 29.24% | 13.61% | 32.66% | 32.77% | 19.07% |
| 10 | 18.90% | 29.08% | 16.62% | 7.76% | 29.24% | 16.13% | 33.38% | 32.77% | 19.93% |
| 20 | 19.73% | 29.79% | 17.47% | 12.15% | 29.24% | 16.13% | 33.38% | 32.77% | 19.07% |
| 30 | 19.73% | 30.51% | 16.62% | 7.76% | 27.11% | 11.93% | 31.95% | 34.19% | 20.78% |
| 40 | 19.73% | 29.08% | 16.62% | 7.76% | 29.24% | 16.13% | 33.38% | 33.48% | 20.87% |
| 50 | 18.91% | 29.08% | 17.47% | 12.15% | 29.24% | 13.61% | 33.38% | 32.78% | 20.02% |
| 75 | 19.73% | 29.08% | 15.77% | 12.15% | 25.70% | 16.13% | 32.68% | 34.19% | 19.17% |
| 100 | 20.55% | 30.51% | 16.94% | 12.15% | 30.25% | 11.93% | 31.96% | 34.19% | 19.17% |

Tabela 7.3: Trasa I - czasy wykonywania algorytmów

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 3,18 | 0,33 | 0,31 | 0,27 | 0,35 | 0,3 | 2,04 | 0,33 | 0,3 |
| 5 | 2,92 | 0,31 | 0,34 | 0,31 | 1,83 | 4,42 | 4,25 | 3,59 | 0,3 |
| 10 | 1,56 | 0,31 | 12,14 | 1,39 | 2,07 | 11,75 | 7,91 | 3,9 | 0,32 |
| 20 | 16,27 | 0,32 | 14,1 | 2,61 | 2,13 | 13,85 | 8,03 | 7,84 | 0,33 |
| 30 | 26,95 | 0,32 | 22,51 | 6,42 | 2,09 | 19,54 | 8,2 | 8,22 | 0,36 |
| 40 | 43,77 | 0,31 | 23,73 | 13,27 | 2,2 | 19,56 | 8,29 | 17,18 | 2,27 |
| 50 | 15,74 | 0,33 | 23,29 | 14,32 | 2 | 20,05 | 8,29 | 23,84 | 9,16 |
| 75 | 25,51 | 0,33 | 24,11 | 14,75 | 2,2 | 20,81 | 34,28 | 5,22 | 11,01 |
| 100 | 35,77 | 0,31 | 24,76 | 21,13 | 11,57 | 21,32 | 13 | 6,1 | 11,39 |

7.2 Trasa 2

7.3 Trasa 3


Tabela 7.4: Trasa I - zastosowanie metody 2-opt na powstałych trasach

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 32751 | 31895 | 35997 | 42343 | 32480 | 38497 | 31235 | 30906 | 36361 |
| 5 | 32751 | 32552 | 37925 | 42343 | 30855 | 39651 | 30906 | 30205 | 36708 |
| 10 | 32751 | 32552 | 35997 | 40319 | 30855 | 38496 | 29965 | 30205 | 36708 |
| 20 | 32751 | 31895 | 37879 | 40319 | 30855 | 38496 | 29965 | 30205 | 36708 |
| 30 | 32751 | 31895 | 35997 | 40319 | 33453 | 38496 | 31235 | 30205 | 36361 |
| 40 | 32751 | 32552 | 35997 | 40319 | 30855 | 38496 | 29965 | 30529 | 36317 |
| 50 | 32751 | 32552 | 37879 | 40319 | 30855 | 39651 | 29965 | 30205 | 36708 |
| 75 | 32751 | 32552 | 35997 | 40319 | 34103 | 38496 | 30899 | 30205 | 36708 |
| 100 | 32751 | 31895 | 35997 | 40319 | 32015 | 38496 | 31228 | 30205 | 36708 |

Tabela 7.5: Trasa I - optymalizacja powstałych tras przez metodę 2-opt

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 28,64% | 30,51% | 21,57% | 7,74% | 29,23% | 16,12% | 31,95% | 32,66% | 20,78% |
| 5 | 28,64% | 29,08% | 17,37% | 7,74% | 32,77% | 13,61% | 32,66% | 34,19% | 20,02% |
| 10 | 28,64% | 29,08% | 21,57% | 12,15% | 32,77% | 16,13% | 34,71% | 34,19% | 20,02% |
| 20 | 28,64% | 30,51% | 17,47% | 12,15% | 32,77% | 16,13% | 34,71% | 34,19% | 20,02% |
| 30 | 28,64% | 30,51% | 21,57% | 12,15% | 27,11% | 16,13% | 31,95% | 34,19% | 20,78% |
| 40 | 28,64% | 29,08% | 21,57% | 12,15% | 32,77% | 16,13% | 34,71% | 33,48% | 20,87% |
| 50 | 28,64% | 29,08% | 17,47% | 12,15% | 32,77% | 13,61% | 34,71% | 34,19% | 20,02% |
| 75 | 28,64% | 29,08% | 21,57% | 12,15% | 25,70% | 16,13% | 32,68% | 34,19% | 20,02% |
| 100 | 28,64% | 30,51% | 21,57% | 12,15% | 30,25% | 16,13% | 31,96% | 34,19% | 20,02% |

Porównanie optymalizacji tras z długością oryginalnej trasy.



Rysunek 7.1: Trasa I - porównanie optymalizacji algorytmów z zastosowanie metody 2-opt

Tabela 7.6: Trasa II - wyniki algorytmów zachłannych

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 33789 | 35566 | 35207 | 34130 | 37006 | 37719 | 33412 | 33410 | 33411 |
| 5 | 33447 | 35206 | 35567 | 35836 | 37724 | 35922 | 33771 | 33410 | 33770 |
| 10 | 33447 | 34839 | 34717 | 34130 | 37000 | 37717 | 34131 | 34129 | 33770 |
| 20 | 33106 | 35198 | 35183 | 34130 | 37000 | 35920 | 32856 | 33410 | 33770 |
| 30 | 33789 | 34839 | 34472 | 34130 | 37000 | 35920 | 32856 | 34129 | 33770 |
| 40 | 33106 | 34836 | 34472 | 35836 | 35922 | 36998 | 32856 | 33770 | 33770 |
| 50 | 33789 | 35555 | 32861 | 35836 | 37000 | 36998 | 33563 | 33402 | 33528 |
| 75 | 33106 | 35196 | 32861 | 35154 | 37718 | 35921 | 33208 | 33757 | 33406 |
| 100 | 33106 | 35555 | 32861 | 35836 | 37000 | 35921 | 32855 | 34122 | 33406 |

Tabela 7.7: Trasa II - optymalizacja wyników względem oryginalnej trasy

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 18,47% | 16,04% | 16,31% | 11,68% | 14,63% | 10,28% | 20,69% | 19,43% | 23,95% |
| 5 | 20,12% | 16,04% | 15,46% | 13,36% | 12,07% | 14,56% | 20,69% | 21,13% | 23,13% |
| 10 | 18,47% | 17,74% | 15,46% | 11,68% | 10,40% | 10,28% | 19,85% | 21,20% | 23,99% |
| 20 | 18,47% | 17,79% | 17,17% | 11,90% | 10,42% | 14,56% | 21,54% | 19,51% | 23,99% |
| 30 | 18,47% | 18,60% | 17,17% | 16,10% | 12,13% | 10,28% | 19,85% | 21,20% | 22,36% |
| 40 | 18,47% | 18,60% | 16,31% | 14,01% | 12,13% | 10,28% | 20,69% | 20,35% | 23,18% |
| 50 | 20,12% | 21,24% | 16,80% | 12,64% | 12,13% | 14,56% | 19,85% | 19,51% | 23,18% |
| 75 | 18,47% | 20,43% | 15,95% | 14,30% | 12,13% | 11,99% | 21,54% | 21,98% | 23,99% |
| 100 | 18,47% | 20,43% | 15,95% | 14,30% | 14,69% | 11,99% | 20,05% | 21,98% | 23,18% |

Tabela 7.8: Trasa II - czasy wykonywania algorytmów


| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 8,62 | 1,18 | 70,32 | 0,36 | 0,69 | 1,43 | 1,36 | 0,42 | 1,33 |
| 5 | 8,45 | 1,2 | 70,23 | 0,14 | 0,34 | 1,17 | 0,87 | 0,86 | 1,02 |
| 10 | 16,79 | 1,17 | 70,83 | 0,17 | 14,66 | 1,19 | 0,88 | 0,9 | 8,05 |
| 20 | 18,21 | 56,24 | 71 | 14,26 | 20,29 | 1,18 | 0,17 | 0,94 | 8,1 |
| 30 | 18,59 | 19,32 | 70,64 | 15,13 | 20,94 | 1,18 | 0,97 | 0,92 | 12,01 |
| 40 | 20,18 | 18,93 | 70,52 | 29,12 | 27,52 | 1,19 | 1,64 | 0,92 | 11,91 |
| 50 | 27,71 | 19,6 | 32,93 | 38,78 | 2,3 | 1,18 | 1,67 | 0,99 | 12,1 |
| 75 | 28,7 | 30,26 | 33,98 | 38,49 | 2,42 | 1,19 | 0,33 | 14,6 | 11,87 |
| 100 | 29,23 | 30,53 | 33,48 | 38,93 | 2,64 | 1,22 | 20,59 | 22,06 | 12,09 |

Tabela 7.9: Trasa II - zastosowanie metody 2-opt na powstałych trasach

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 30222 | 30798 | 28938 | 32535 | 32298 | 33298 | 29687 | 30483 | 28773 |
| 5 | 30222 | 30798 | 31479 | 32780 | 33267 | 32328 | 30066 | 29840 | 29083 |
| 10 | 30222 | 30798 | 31479 | 32535 | 33899 | 33298 | 30325 | 29519 | 28757 |
| 20 | 30222 | 30798 | 28938 | 33332 | 33892 | 32328 | 29687 | 30454 | 28757 |
| 30 | 30222 | 30798 | 28938 | 29504 | 32298 | 33298 | 29687 | 29519 | 29066 |
| 40 | 30222 | 30798 | 28938 | 32535 | 32298 | 33298 | 29687 | 30134 | 29066 |
| 50 | 30222 | 29800 | 31479 | 33053 | 32298 | 32328 | 30325 | 30454 | 29066 |
| 75 | 30222 | 29800 | 31479 | 29504 | 32298 | 33298 | 29687 | 29519 | 28757 |
| 100 | 30222 | 29800 | 31479 | 29504 | 32278 | 33298 | 30250 | 29519 | 29066 |

Tabela 7.10: Trasa II - optymalizacja powstałych tras przez metodę 2-opt

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 20,12% | 18,60% | 23,52% | 14,01% | 14,63% | 11,99% | 21,54% | 19,43% | 23,95% |
| 5 | 20,12% | 18,60% | 16,80% | 13,36% | 12,07% | 14,56% | 20,53% | 21,13% | 23,13% |
| 10 | 20,12% | 18,60% | 16,80% | 14,01% | 10,40% | 11,99% | 19,85% | 21,98% | 23,99% |
| 20 | 20,12% | 18,60% | 23,52% | 11,90% | 10,40% | 14,56% | 21,54% | 19,51% | 23,99% |
| 30 | 20,12% | 18,60% | 23,52% | 22,02% | 14,63% | 11,99% | 21,54% | 21,98% | 23,18% |
| 40 | 20,12% | 18,60% | 23,52% | 14,01% | 14,63% | 11,99% | 21,54% | 20,35% | 23,18% |
| 50 | 20,12% | 21,24% | 16,80% | 12,64% | 14,63% | 14,56% | 19,85% | 19,51% | 23,18% |
| 75 | 20,12% | 21,24% | 16,80% | 22,02% | 14,63% | 11,99% | 21,54% | 21,98% | 23,99% |
| 100 | 20,12% | 21,24% | 16,80% | 22,02% | 14,69% | 11,99% | 20,05% | 21,98% | 23,18% |



Rysunek 7.2: Trasa II - porównanie optymalizacji algorytmów z zastosowaniem metody 2-opt

Tabela 7.11: Trasa III - wyniki algorytmów zachłannych

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 33789 | 35566 | 35207 | 34130 | 37006 | 37719 | 33412 | 33410 | 33411 |
| 5 | 33447 | 35206 | 35567 | 35836 | 37724 | 35922 | 33771 | 33410 | 33770 |
| 10 | 33447 | 34839 | 34717 | 34130 | 37000 | 37717 | 34131 | 34129 | 33770 |
| 20 | 33106 | 35198 | 35183 | 34130 | 37000 | 35920 | 32856 | 33410 | 33770 |
| 30 | 33789 | 34839 | 34472 | 34130 | 37000 | 35920 | 32856 | 34129 | 33770 |
| 40 | 33106 | 34836 | 34472 | 35836 | 35922 | 36998 | 32856 | 33770 | 33770 |
| 50 | 33789 | 35555 | 32861 | 35836 | 37000 | 36998 | 33563 | 33402 | 33528 |
| 75 | 33106 | 35196 | 32861 | 35154 | 37718 | 35921 | 33208 | 33757 | 33406 |
| 100 | 33106 | 35555 | 32861 | 35836 | 37000 | 35921 | 32855 | 34122 | 33406 |

Tabela 7.12: Trasa III - optymalizacja wyników względem oryginalnej trasy

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 27,13% | 23,30% | 24,08% | 26,40% | 20,20% | 18,66% | 27,95% | 27,95% | 27,95% |
| 5 | 27,87% | 24,08% | 23,30% | 22,72% | 18,65% | 22,54% | 27,17% | 27,95% | 27,18% |
| 10 | 27,87% | 24,87% | 25,13% | 26,40% | 20,21% | 18,66% | 26,40% | 26,40% | 27,18% |
| 20 | 28,61% | 24,10% | 24,13% | 26,40% | 20,21% | 22,54% | 29,15% | 27,95% | 27,18% |
| 30 | 27,13% | 24,87% | 25,66% | 26,40% | 20,21% | 22,54% | 29,15% | 26,40% | 27,18% |
| 40 | 28,61% | 24,88% | 25,66% | 22,72% | 22,54% | 20,21% | 29,15% | 27,18% | 27,18% |
| 50 | 27,13% | 23,33% | 29,14% | 22,72% | 20,21% | 20,21% | 27,62% | 27,97% | 27,70% |
| 75 | 28,61% | 24,10% | 29,14% | 24,19% | 18,66% | 22,54% | 28,39% | 27,20% | 27,96% |
| 100 | 28,61% | 23,33% | 29,14% | 22,72% | 20,21% | 22,54% | 29,15% | 26,42% | 27,96% |

Tabela 7.13: Trasa III - czasy wykonywania algorytmów

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|--------|-------|-------|--------|-------|--------|-------|
| 0 | 39,19 | 2,26 | 41,38 | 17,08 | 0,66 | 0,98 | 14,68 | 2,98 | 22,87 |
| 5 | 49,02 | 1,63 | 39,12 | 24,32 | 0,38 | 26,84 | 30,63 | 2,91 | 22,38 |
| 10 | 51,45 | 38,71 | 39,76 | 25,9 | 0,46 | 40,75 | 43,69 | 2,98 | 32,58 |
| 20 | 65,1 | 38,18 | 41,37 | 27,3 | 0,59 | 42,28 | 0,57 | 8,31 | 32,35 |
| 30 | 85,67 | 39,24 | 58,65 | 26,81 | 0,71 | 95,72 | 0,71 | 8,69 | 32,62 |
| 40 | 87,95 | 99,26 | 83,85 | 26,98 | 0,77 | 137,77 | 0,9 | 0,71 | 32,72 |
| 50 | 88,71 | 19,47 | 125,16 | 34,24 | 0,8 | 184,5 | 1,23 | 83,84 | 34,2 |
| 75 | 91,05 | 20,8 | 127,13 | 33,87 | 4,53 | 186,57 | 6,52 | 119,22 | 18,12 |
| 100 | 92,9 | 21,06 | 178,76 | 34,52 | 4,89 | 100,17 | 7,66 | 11,8 | 26,5 |


Tabela 7.14: Trasa III - zastosowanie metody 2-opt na powstałych trasach

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 33447 | 35566 | 35207 | 34130 | 37006 | 37719 | 33208 | 33410 | 33411 |
| 5 | 33447 | 35206 | 35567 | 34130 | 37724 | 35922 | 33208 | 33410 | 32756 |
| 10 | 33447 | 34839 | 34717 | 34130 | 35922 | 37717 | 33208 | 33410 | 32756 |
| 20 | 31781 | 35198 | 35183 | 34130 | 35922 | 35920 | 32856 | 33410 | 32756 |
| 30 | 33447 | 34839 | 32861 | 34130 | 35922 | 35920 | 32856 | 33410 | 32756 |
| 40 | 31781 | 34836 | 32861 | 34130 | 35922 | 35920 | 32856 | 33770 | 32756 |
| 50 | 33447 | 34839 | 32861 | 34130 | 35922 | 35920 | 33208 | 33402 | 33528 |
| 75 | 31781 | 35196 | 32861 | 35154 | 35454 | 35921 | 33208 | 33757 | 33406 |
| 100 | 31781 | 34839 | 32861 | 34130 | 35922 | 35921 | 32855 | 33410 | 33406 |

Tabela 7.15: Trasa III - optymalizacja powstałych tras przez metodę 2-opt

| Błąd (m) | ANS-1 | ANS-2 | ANS-3 | ANK-1 | ANK-2 | ANK-3 | A*-1 | A*-2 | A*-3 |
|----------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0 | 28,16% | 23,54% | 24,33% | 26,67% | 20,41% | 18,85% | 28,68% | 28,24% | 28,24% |
| 5 | 28,16% | 24,33% | 23,54% | 26,67% | 18,84% | 22,77% | 28,68% | 28,24% | 29,67% |
| 10 | 28,16% | 25,13% | 25,39% | 26,67% | 22,77% | 18,86% | 28,68% | 28,24% | 29,67% |
| 20 | 31,79% | 24,35% | 24,38% | 26,67% | 22,77% | 22,77% | 29,45% | 28,24% | 29,67% |
| 30 | 28,16% | 25,13% | 29,44% | 26,67% | 22,77% | 22,77% | 29,45% | 28,24% | 29,67% |
| 40 | 31,79% | 25,13% | 29,44% | 26,67% | 22,77% | 22,77% | 29,45% | 27,49% | 29,67% |
| 50 | 28,16% | 25,13% | 29,44% | 26,67% | 22,77% | 22,77% | 28,68% | 28,24% | 27,98% |
| 75 | 31,79% | 24,35% | 29,44% | 24,44% | 23,79% | 22,77% | 28,68% | 27,49% | 28,25% |
| 100 | 31,79% | 25,13% | 29,44% | 26,67% | 22,77% | 22,77% | 29,45% | 28,24% | 28,25% |

Porównanie optymalizacji tras z długością oryginalnej trasy.



Rysunek 7.3: Trasa III - porównanie optymalizacji algorytmów z zastosowanie metody 2-opt

Podsumowanie

Dzięki wykorzystaniu realnych danych do optymalizacji ścieżek przejazdów ciężarówek z odpadami komunalnymi można zbadać oraz zaproponować rozwiązanie problemu. Wybrane ścieżki stanowią faktyczne trasy jakie były przebywane. Wybrane trzy losowo trasy składały się odpowiednio z 110, 150 oraz 249 punktów. Dzięki udostępnionym rozwiązaniu przez firmę Google, zostały wyliczone rzeczywiste odległości pomiędzy wszystkimi punktami.

Do optymalizacji zostały wybrane trzy algorytmy. Algorytm genetyczny który został opisany w rozdziale 2. W następnym rozdziale został przedstawiony algorytm mrówkowy. Jako ostatnie zostały zaproponowanych kilka algorytmów zachłannych. Dla każdego z rozwiązań została przygotowana część teoretyczna oraz zostały przeprowadzone badania.

Schemat badań dla każdej z tras był taki sam niezależnie od algorytmu. Dla każdej możliwej konfiguracji parametrów wejściowych zostało wykonanych dziesięć badań. Algorytm genetyczny składa się z... . W algorytmie mrówkowym parametrami wejściowymi była liczba iteracji oraz współczynnik parowania feromonów. Wykonanych było 50, 75 lub 100 iteracji a współczynnik zakresu był rozpoczynał się od 0.1 i był zwiększany do 0.9 co 0.1. W ten sposób dla jednej trasy było wykonanych 270 badań. Algorytm zachłanny...

Po przeprowadzeniu badań z pewnością można powiedzieć, że pierwotne trasy nie były optymalne. Omówione rozwiązania były w stanie poprawić oryginalną trasę nawet o 40%. Każdy z algorytmów był w stanie wygenerować wiele krótszych tras. Najlepsze wyniki były generowane przez algorytm mrówkowy. Jeśli chodzi o czas, to najszybciej działał algorytm genetyczny. Warto również zaznaczyć, że wyniki tego algorytmu również były satysfakcjonujące.

Przeprowadzone badania pokazują jak można rozwiązać problem z którym nawet nieświadomie borykają się firmy. Dla każdego z rozwiązań można się zastanowić nad udoskonaleniami. Algorytm genetyczny... . Dość długi czas działania algorytmu mrówkowego jest z pewnością miejscem nad którym można popracować. Algorytm zachłanny...

Bibliografia

- [1] J. Autor. Nazwa strony internetowej. `http://www.dlugi.adres.url.zlamie.sie.gdzies.w.srodku.com`, stan z 01.01.2010 r.
- [2] U. Autor and W. Kolejny. Tytuł publikacji. *Nazwa czasopisma*, 12(2):132–145, May 2012.
- [3] Ewa Figielska. Algorytmy ewolucyjne i ich zastosowania. *Zeszyty Naukowe Warszawskiej Wyższej Szkoły Informatyki*, 1(1):81–92, 2006.
- [4] Anna Gryko-Nikitin. Niektóre osobliwości algorytmów genetycznych na przykładzie zagadnień logistycznych. *Ekonomia i Zarządzanie*, 1(2):129–138, 2010.
- [5] B. Inny. Tytuł publikacji. In *Tytuł książki*, pages 5–32, Feb 2011.
- [6] Z. Test and K. Następny. *Tytuł książki*. Wydawca, Adres, 1995.
- [7] Radosław Winiczenko. Algorytmy genetyczne i ich zastosowania. *Postępy Techniki Przetwórstwa Spożywczego*, 1(2):107–110, 2008.

Spis tabel

| | | |
|--------------|--|----|
| Tablica 3.1 | Krótki podpis tabeli 1 – do spisu treści | 35 |
| Tablica 3.2 | Krótki podpis tabeli 1 – do spisu treści | 35 |
| Tablica 6.1 | Trasa I - średnie wyniki dla algorytmu genetycznego | 50 |
| Tablica 6.2 | Trasa I - tbd dla algorytmu genetycznego | 51 |
| Tablica 6.3 | Trasa I - najlepsze wyniki dla algorytmu genetycznego | 51 |
| Tablica 6.4 | Trasa I - średnie czasy wykonywania algorytmu genetycznego | 52 |
| Tablica 6.5 | Trasa I - najlepsze wyniki dla algorytmu mrówkowego | 55 |
| Tablica 6.6 | Trasa I - średnie wyniki dla algorytmu mrówkowego | 55 |
| Tablica 6.7 | Trasa I - suma lepszych tras w porównaniu do oryginalnej | 55 |
| Tablica 6.8 | Trasa I - średnie wyniki czasu wykonania dla algorytmu mrówko- wego dla parametru ilości iteracji | 57 |
| Tablica 6.9 | Trasa II - średnie wyniki dla algorytmu genetycznego | 63 |
| Tablica 6.10 | Trasa II - tbd dla algorytmu genetycznego | 63 |
| Tablica 6.11 | Trasa II - najlepsze wyniki dla algorytmu genetycznego | 64 |
| Tablica 6.12 | Trasa II - średnie czasy wykonywania algorytmu genetycznego | 64 |
| Tablica 6.13 | Trasa II - najlepsze wyniki dla algorytmu mrówkowego | 66 |
| Tablica 6.14 | Trasa II - średnie wyniki dla algorytmu mrówkowego | 66 |
| Tablica 6.15 | Trasa II - suma lepszych tras w porównaniu do oryginalnej | 68 |
| Tablica 6.16 | Trasa II - średnie wyniki czasu wykonania dla algorytmu mrówko- wego dla parametru ilości iteracji | 69 |
| Tablica 6.17 | Trasa III -średnie wyniki dla algorytmu genetycznego | 72 |
| Tablica 6.18 | Trasa III - tbd dla algorytmu genetycznego | 73 |
| Tablica 6.19 | Trasa III - najlepsze wyniki dla algorytmu genetycznego | 73 |
| Tablica 6.20 | Trasa III - średnie czasy wykonywania algorytmu genetycznego . . . | 74 |
| Tablica 6.21 | Trasa III - średnie wyniki dla algorytmu mrówkowego | 76 |
| Tablica 6.22 | Trasa III - najlepsze wyniki dla algorytmu mrówkowego | 76 |
| Tablica 6.23 | Trasa III - suma lepszych tras w porównaniu do oryginalnej | 78 |
| Tablica 6.24 | Trasa III - średnie wyniki czasu wykonania dla algorytmu mrówko- wego dla parametru ilości iteracji | 78 |

| | | |
|--------------|--|----|
| Tablica 7.1 | Trasa I - wyniki algorytmów zachłannych | 83 |
| Tablica 7.2 | Trasa I - optymalizacja wyników względem oryginalnej trasy | 83 |
| Tablica 7.3 | Trasa I - czasy wykonywania algorytmów | 83 |
| Tablica 7.4 | Trasa I - zastosowanie metody 2-opt na powstałych trasach | 84 |
| Tablica 7.5 | Trasa I - optymalizacja powstałych tras przez metodę 2-opt | 84 |
| Tablica 7.6 | Trasa II - wyniki algorytmów zachłannych | 84 |
| Tablica 7.7 | Trasa II - optymalizacja wyników względem oryginalnej trasy | 85 |
| Tablica 7.8 | Trasa II - czasy wykonywania algorytmów | 85 |
| Tablica 7.9 | Trasa II - zastosowanie metody 2-opt na powstałych trasach | 85 |
| Tablica 7.10 | Trasa II - optymalizacja powstałych tras przez metodę 2-opt | 85 |
| Tablica 7.11 | Trasa III - wyniki algorytmów zachłannych | 86 |
| Tablica 7.12 | Trasa III - optymalizacja wyników względem oryginalnej trasy | 86 |
| Tablica 7.13 | Trasa III - czasy wykonywania algorytmów | 86 |
| Tablica 7.14 | Trasa III - zastosowanie metody 2-opt na powstałych trasach | 87 |
| Tablica 7.15 | Trasa III - optymalizacja powstałych tras przez metodę 2-opt | 87 |

Spis rysunków

| | | |
|--------------|--|----|
| Rysunek 1.1 | Graf bez cyklu Hamiltona. | 14 |
| Rysunek 1.2 | Graf z cyklem Hamiltona. | 14 |
| Rysunek 2.1 | Schemat algorytmu genetycznego | 22 |
| Rysunek 2.2 | Metoda ruletki | 23 |
| Rysunek 2.3 | Klasyczne krzyżowanie | 24 |
| Rysunek 2.4 | Mutacja genotypu | 24 |
| Rysunek 2.5 | Kodowanie chromosomów | 25 |
| Rysunek 2.6 | Krzyżowanie PMX - część 1 | 26 |
| Rysunek 2.7 | Krzyżowanie PMX - część 2 | 27 |
| Rysunek 2.8 | Krzyżowanie OX | 27 |
| Rysunek 2.9 | Krzyżowanie CX | 28 |
| Rysunek 2.10 | Mutacja odwracająca | 29 |
| Rysunek 2.11 | Mutacja wstawiająca | 30 |
| Rysunek 2.12 | Mutacja zamieniająca | 30 |
| Rysunek 3.1 | Położenie ścieżek na przykładowym grafie | 33 |
| Rysunek 3.2 | Rozkład agentów na grafie po N początkowych iteracjach | 33 |
| Rysunek 3.3 | Rozkład agentów w grafie po optymalizacji | 34 |
| Rysunek 3.4 | Graf z wagami | 35 |
| Rysunek 3.5 | Graf z początkowymi wartościami feromonów | 36 |
| Rysunek 3.6 | Trasa przebyta przez agenta L1 | 37 |
| Rysunek 3.7 | Trasa przebyta przez agenta L2 | 37 |
| Rysunek 3.8 | Graf z wartościami feromonów po modyfikacji | 38 |
| Rysunek 4.1 | Schemat algorytmu najbliższego sąsiada | 40 |
| Rysunek 4.2 | Algorytm najbliższego sąsiada | 41 |
| Rysunek 4.3 | Schemat algorytmu najmniejszej krawędzi | 42 |
| Rysunek 4.4 | Początkowe rozmieszczenie wierzchołków | 43 |
| Rysunek 4.5 | Algorytm najmniejszej krawędzi | 43 |
| Rysunek 4.6 | Metoda 2-opt | 45 |

| | | |
|--------------|--|----|
| Rysunek 4.7 | Metoda 3-opt | 45 |
| Rysunek 6.1 | Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=100 | 53 |
| Rysunek 6.2 | Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=1000 | 53 |
| Rysunek 6.3 | Trasa I - porównanie średnich wyników z długością oryginalnej trasy dla N=2000 | 54 |
| Rysunek 6.4 | Procentowy rozkład średnich wartości dla 50 iteracji | 56 |
| Rysunek 6.5 | Procentowy rozkład średnich wartości dla 75 iteracji | 57 |
| Rysunek 6.6 | Procentowy rozkład średnich wartości dla 100 iteracji | 58 |
| Rysunek 6.7 | Fragment trasy algorytmu genetycznego | 60 |
| Rysunek 6.8 | Fragment trasy algorytmu mrówkowego | 61 |
| Rysunek 6.9 | Fragment trasy algorytmu A* | 62 |
| Rysunek 6.10 | Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=100 | 65 |
| Rysunek 6.11 | Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=1000 | 65 |
| Rysunek 6.12 | Trasa II - porównanie średnich wyników z długością oryginalnej trasy dla N=2000 | 66 |
| Rysunek 6.13 | Procentowy rozkład średnich wartości dla 50 iteracji | 67 |
| Rysunek 6.14 | Procentowy rozkład średnich wartości dla 75 iteracji | 68 |
| Rysunek 6.15 | Procentowy rozkład średnich wartości dla 100 iteracji | 69 |
| Rysunek 6.16 | Fragment trasy algorytmu genetycznego | 70 |
| Rysunek 6.17 | Fragment trasy algorytmu mrówkowego | 71 |
| Rysunek 6.18 | Fragment trasy algorytmu A* | 71 |
| Rysunek 6.19 | Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=100 | 74 |
| Rysunek 6.20 | Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=1000 | 75 |
| Rysunek 6.21 | Trasa III - porównanie średnich wyników z długością oryginalnej trasy dla N=2000 | 75 |
| Rysunek 6.22 | Wykres 1 | 77 |

| | |
|--|----|
| Rysunek 6.23 Wykres 1 | 78 |
| Rysunek 6.24 Wykres 1 | 79 |
| Rysunek 6.25 Fragment trasy algorytmu genetycznego | 80 |
| Rysunek 6.26 Fragment trasy algorytmu mrówkowego | 81 |
| Rysunek 6.27 Fragment trasy algorytmu najbliższego sąsiada | 81 |
| Rysunek 7.1 Trasa I - porównanie optymalizacji algorytmów z zastosowanie metody 2-opt | 84 |
| Rysunek 7.2 Trasa II - porównanie optymalizacji algorytmów z zastosowanie metody 2-opt | 86 |
| Rysunek 7.3 Trasa III - porównanie optymalizacji algorytmów z zastosowanie metody 2-opt | 87 |

Spis listingów

Spis algorytmów